

一、绪论

温铁祥
健康与环境工程学院

深圳技术大学
SHENZHEN TECHNOLOGY UNIVERSITY

机器学习

机器学习是从人工智能中产生的一个重要学科分支，是实现智能化的关键

经典定义： 利用经验改善系统自身的性能



经验 → 数据



随着该领域的发展，目前主要研究**智能数据分析**的理论和算法，并已成智能数据分析技术的源泉之一


图灵奖



Leslie Valiant
(1949 -)
(Harvard Univ.)


2011
年度

诺贝尔物理学奖




**Hopfield
& Hinton**

2024
年度



机器学习 (Machine Learning)




究竟是什么东东？

当前应用 ➡

大语言模型（LLM）



欢迎使用  Qwen3.8-Max ▾ 大模型




生成式AI（Generative AI）



Stable Diffusion




OpenAI Sora



AlphaFold3

开启你的 **Agent 模式** 即刻造梦！




具身智能（Embodied AI）

e.g. ACT -> Diffusion Policy -> π $\rightarrow$ VLA

从赛场惊艳到产业深耕
中国机器人加速领跑全球（国际论道）
本报记者 张 红

2026年08月31日09:32 | 来源：人民网 - 人民日报海外版

☆ 收藏 T 小字号



机器学习能做什么？



小数据上也很有用

机器学习源自“人工智能”

Artificial Intelligence (AI), 1956 -

1956年夏 美国达特茅斯学院

J. McCarthy, M. Minsky, N. Lochester, C. E. Shannon,
H.A. Simon, A. Newell, A. L. Samuel 等10余人



约翰 麦卡锡
(1927-2011)
“人工智能之父”
1971年图灵奖

达特茅斯会议标志着人工智能这一学科的诞生

John McCarthy (1927 - 2011):

1971年获图灵奖, 1985年获IJCAI终身成就奖。人工智能之父。他提出了“人工智能”的概念, 设计出函数型程序设计语言Lisp, 发展了递归的概念, 提出常识推理和情境演算。出生于共产党家庭, 从小阅读《10万个为什么》, 中学时自修CalTech的数学课程, 17岁进入CalTech时免修两年数学, 22岁在Princeton获博士学位, 37岁担任Stanford大学AI实验室主任。

第一阶段：推理期

1956-1960s: Logic Reasoning

- ◆ 出发点：“数学家真聪明！”
- ◆ 主要成就：自动定理证明系统 (例如，西蒙与纽厄尔的“Logic Theorist”系统)

渐渐地，研究者们意识到，仅有逻辑推理能力是不够的 ...



赫伯特 西蒙
(1916-2001)
1975年图灵奖



阿伦 纽厄尔
(1927-1992)
1975年图灵奖

第二阶段：知识期

1970s -1980s: Knowledge Engineering

- ◆ 出发点：“知识就是力量！”
- ◆ 主要成就: 专家系统 (例如，费根鲍姆等人的“DENDRAL”系统)



爱德华 费根鲍姆
(1936-)
1994年图灵奖

渐渐地，研究者们发现，要总结出知识再“教”给系统，实在太难了 ...

第二阶段：知识期




Figure 1-1. The traditional approach

渐渐地，研究者们发现，要总结出知识再“教”给系统，实在太难了 ...

第三阶段：学习期

1990s -now: Machine Learning

- ◆ 出发点：“让系统自己学！”
- ◆ 主要成就：.....

机器学习是作为“突破知识工程瓶颈”
之利器而出现的



恰好在20世纪90年代中后期，人类发现自己淹没在数据的汪洋中，对自动数据分析技术——机器学习的需求日益迫切

第三阶段：学习期




Figure 1-2. The Machine Learning approach

恰好在20世纪90年代中后期，人类发现自己淹没在数据的汪洋中，对自动数据分析技术——机器学习的需求日益迫切


大数据时代，机器学习必不可少

收集、传输、存储大数据的目的，
是为了“利用”大数据

没有机器学习技术分析大数据，
“利用”无从谈起


基本术语

- 监督学习(supervised learning)
- 无监督学习(unsupervised learning)



- 数据集: 训练, 测试
- 示例(instance), 样本(sample)
- 属性(attribute), 特征(feature); 属性值
- 属性空间, 样本空间, 输入空间
- 特征向量(feature vector)
- 标记空间, 输出空间

问题的形式化



$$\mathbf{x}_i = \begin{bmatrix} x_1^i \\ x_2^i \\ \vdots \\ x_d^i \end{bmatrix}$$

样本

m : 输入的样本个数

d : 样本的特征维数

分类: 例 $y_i = \pm 1$

回归: y_i 为连续值

损失函数:

$$L(\mathbf{w}) = \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2 = \|f(\mathbf{x}) - \mathbf{y}\|_2^2$$

问题的形式化

机器学习 $\approx$ 构建一个映射函数


▶ 语音识别

$$f(\text{ ) = \text{“你好”}$$

▶ 图像识别

$$f(\text{ ) = \text{“9”}$$

▶ 围棋

$$f(\text{ ) = \text{“6-5”} \quad (\text{落子位置})$$

▶ 机器翻译

$$f(\text{“你好!”}) = \text{“Hello!”}$$

损失函数

- 0-1 loss function

$$L(Y, f(X)) = \begin{cases} 1, Y \neq f(X) \\ 0, Y = f(X) \end{cases}$$

- quadratic loss function

$$L(Y, f(X)) = (Y - f(X))^2$$

- absolute loss function

$$L(Y, f(X)) = |Y - f(X)|$$

- logarithmic loss function (log-likelihood loss function)

$$L(Y, P(Y|X)) = -\log P(Y|X)$$

损失函数值越小，模型越好。

特征向量

□ 向量的大小:

$$\|\vec{x}\|_2^2 = \vec{x}^T \cdot \vec{x} = \sum_{i=1}^d x_i^2$$

□ 向量的方向:

$$\vec{x}_{normal} = \frac{\vec{x}}{\|\vec{x}\|}$$

$$\vec{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

$$\vec{x}^T = \begin{bmatrix} x_1 & x_2 & \cdots & x_d \end{bmatrix}^T$$

d维特征向量

向量的转置


特征向量

- p 范数 (p -norm) $\|\vec{x}\|_p = \left(|x_1|^p + |x_2|^p + \dots + |x_d|^p\right)^{\frac{1}{p}}$
- ℓ_2 范数 $\|\vec{x}\|_2 = \left(|x_1|^2 + |x_2|^2 + \dots + |x_d|^2\right)^{\frac{1}{2}}$
- ℓ_1 范数 $\|\vec{x}\|_1 = (|x_1| + |x_2| + \dots + |x_d|)$
- ℓ_∞ 范数 $\|\vec{x}\|_\infty = \max(|x_1|, |x_2|, \dots, |x_d|)$
- ℓ_0 范数: 向量中非零元素的个数


$$\vec{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

特征向量


p 范数 (p -norm) 的几何图形




(a) $p=0.5$



(b) $p=1$



(c) $p=2$



(d) $p \rightarrow \infty$

特征向量

向量点积：特性向量的相似性度量（余弦距离）

$$\langle \vec{x}, \vec{y} \rangle = \vec{x}^T \cdot \vec{y}$$

$$\langle \vec{x}, \vec{y} \rangle = x_1 y_1 + x_2 y_2 + \dots + x_n y_n = |\vec{x}| \cdot |\vec{y}| \cdot \cos \theta$$


$$\vec{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} \quad \vec{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_d \end{bmatrix}$$

向量点积的几何意义：

1) 度量了向量的相似程度，

$\theta = 0$ ：完全相关， $\theta = 90$ ：完全不相关。

2) 描述了一个向量在另一个向量上的投影长度。



假设空间

表 1.1 西瓜数据集

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	浊响	是
3	青绿	硬挺	清脆	否
4	乌黑	稍蜷	沉闷	否

$(\text{色泽}=?)\wedge(\text{根蒂}=?)\wedge(\text{敲声}=?)\leftrightarrow \text{好瓜}$

学习过程 → 在所有假设(hypothesis)组成的空间中进行搜索的过程

机器学习目标: 找到与训练集“匹配”的假设

假设空间的大小: $(n_1+1) \times (n_2+1) \times (n_3+1) + 1$

假设空间





表 1.1 西瓜数据集

编号	色泽	根蒂	敲声
1	青绿	蜷缩	浊响
2	乌黑	蜷缩	浊响
3	青绿	硬挺	清脆
4	乌黑	稍蜷	沉闷

编号	好瓜
1	是
2	是
3	否
4	否


• 决策函数的集合: $\mathcal{F} = \{f|Y = f(X)\}$



• 条件概率的集合: $\mathcal{F} = \{P|P(Y|X)\}$

版本空间

版本空间(version space): 与训练集一致的假设集合




在面临新样本时, 会产生不同的输出
例如: (青绿; 蜷缩; 沉闷)

应该采用哪一个
模型(假设)?

归纳偏好 (inductive bias)

机器学习算法在学习过程中对某种类型假设的偏好




任何一个有效的机器学习算法必有其偏好

奥卡姆剃刀(Ocam's razor)原则:


- 若存在多个假设与观察一致，则选最简单的那个。

哪个算法更好？

没有免费的午餐！



(a) A 优于 B



(b) B 优于 A

图 1.4 没有免费的午餐. (黑点: 训练样本; 白点: 测试样本)

NFL定理: 一个算法 $\mathcal{L}_a$ 若在某些问题上比另一个算法 $\mathcal{L}_b$ 好, 必存在另一些问题, $\mathcal{L}_b$ 比 $\mathcal{L}_a$ 好。

NFL定理的寓意

NFL定理的重要前提：

所有“问题”出现的机会相同、或所有问题同等重要

实际情形并非如此；我们通常只关注自己正在试图解决的问题

脱离具体问题，空泛地谈论“什么学习算法更好”
毫无意义！

机器学习系统的类型

□ 有监督学习（supervised learning）

- 训练数据集包含标签

分类问题 (Classification)




Figure 1-5. A labeled training set for spam classification (an example of supervised learning)

回归问题 (Regression)




Figure 1-6. A regression problem: predict a value, given an input feature (there are usually multiple input features, and sometimes multiple output values)

机器学习系统的类型

□ 无监督学习（unsupervised learning）

- 训练数据未经标记
- e.g. 关于博客访客的数据,
 $x_{\text{访客}_1} = \{\text{性别, 年龄, 访问时间, 兴趣爱好, ...}\}$




Figure 1-7. An unlabeled training set for unsupervised learning

机器学习系统的类型

□ 无监督学习（unsupervised learning）

- 聚类算法：k-均值，DBSCAN（第9章）
- 可视化和降维：PCA（第10章）
- 关联规则学习：Apriori




Figure 1-8. Clustering

机器学习系统的类型

□ 半监督学习（semisupervised learning）

- 数据的标注通常耗时且昂贵
- 可标注少量数据用于训练




Figure 1-11. Semisupervised learning with two classes (triangles and squares): the unlabeled examples (circles) help classify a new instance (the cross) into the triangle class rather than the square class, even though it is closer to the labeled squares

机器学习系统的类型

❑ 强化学习（Reinforcement learning）

- 学习系统（**智能体**）能够观测**环境**，根据**策略**做出选择，执行**动作**，并获得**回报或惩罚**。
- 特点：自学习




Figure 1-12. Reinforcement Learning

机器学习系统的类型

□ 批量学习和在线学习

➤ 批量学习（batch learning）

- 使用所有可用数据进行训练，通常是离线完成的（**离线学习，offline learning**）。
- 训练过程通常需要占用大量资源。

机器学习系统的类型

❑ 批量学习和在线学习

➤ 在线学习 (online learning)

- 一种增量学习算法，可循序渐进的给系统提供训练数据。




Figure 1-13. In online learning, a model is trained and launched into production, and then it keeps learning as new data comes in

机器学习系统的类型

□ 批量学习和在线学习

➤ 在线学习（online learning）

- 挑战：如果给系统输入不良数据系统的性能会逐渐下降。
- 不良数据来源：传感器故障、恶意刷屏
- 应对手段：密切监控系统，一旦检测到性能下降，就及时中断学习。

机器学习系统的类型

□ 基于实例的学习与基于模型的学习

- 基于实例的学习（instance-based learning）
 - 学习系统记住训练实例样本，然后使用相似度量来比较新实例和已经学习实例（或它们的子集），从而泛化新实例（即对系统未见过的新实例进行预测）。



Figure 1-15. Instance-based learning

机器学习系统的类型

□ 基于实例的学习与基于模型的学习

- 基于模型的学习（**model-based learning**）
 - 先根据训练示例构建模型，然后使用该模型进行预测。




Figure 1-16. Model-based learning

机器学习系统的类型

- ❑ 基于模型的学习实例：金钱能否让人更快乐？
 - 经合组织（OECD）：“幸福指数”数据
 - 国际货币基金组织（IMF）：人均GDP统计数据
 - 研究数据（可视化）

Table 1-1. Does money make people happier?

Country	GDP per capita (USD)	Life satisfaction
Hungary	12,240	4.9
Korea	27,195	5.8
France	37,675	6.5
Australia	50,962	7.3
United States	55,805	7.2




Figure 1-17. Do you see a trend here?

机器学习系统的类型

□ 基于模型的学习实例：金钱能否让人更快乐？

- 选择模型：线性模型？

$$\text{life_satisfaction} = \theta_0 + \theta_1 \times \text{GDP_per_capita}$$

- 训练：确定模型的参数 θ_0, θ_1
- 预测




Figure 1-19. The linear model that fits the training data best

机器学习系统的类型

□ 基于模型的学习实例：金钱能否让人更快乐？

Example 1-1. Training and running a linear model using Scikit-Learn

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import sklearn.linear_model

# Load the data
oecd_bli = pd.read_csv("oecd_bli_2015.csv", thousands=',')
gdp_per_capita =
pd.read_csv("gdp_per_capita.csv",thousands=',',delimiter='\t',
            encoding='latin1', na_values="n/a")

# Prepare the data
country_stats = prepare_country_stats(oecd_bli, gdp_per_capita)
X = np.c_[country_stats["GDP per capita"]]
y = np.c_[country_stats["Life satisfaction"]]

# Visualize the data
country_stats.plot(kind='scatter', x="GDP per capita", y='Life
satisfaction')
plt.show()

# Select a linear model
model = sklearn.linear_model.LinearRegression()

# Train the model
model.fit(X, y)

# Make a prediction for Cyprus
X_new = [[22587]] # Cyprus's GDP per capita
print(model.predict(X_new)) # outputs [[ 5.96242338]]
```

使用pandas进行csv数据的读取

数据预处理，转换成numpy数组


使用matplotlib进行数据查看

使用sklearn选择模型，
并进行模型的训练

使用训练好的模型进行预测

机器学习系统的类型

❑ 基于模型的学习实例：金钱能否让人更快乐？



机器学习系统的类型

□ 基于模型的学习实例：金钱能否让人更快乐？

- 如果不满意预测效果，则需要使用更多的属性
（例如， $\mathbf{x}_{\text{国家}} = \{\text{GDP}, \text{就业率}, \text{健康}, \text{空气污染}, \dots\}$ ），
获得更多或更高质量的训练数据，或者选择一个更强大的模型
（例如，多项式回归模型）

$$f(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots = \sum_{i=0}^d \theta_i x_i = \boldsymbol{\theta}^T \mathbf{x} = \mathbf{x}^T \boldsymbol{\theta}$$

机器学习系统的类型

❑ 基于模型的学习实例：金钱能否让人更快乐？

➤ 例如：选择多元线性回归模型

($\mathbf{x}_{\text{国家}} = \{\text{GDP, 就业率, 健康, 空气污染}\}$)

- $\mathbf{x}^{(i)}$: 第 i 个实例的特征向量

$$\mathbf{x}^{(1)} = \begin{bmatrix} 50962 \\ 72 \\ 85 \\ 13 \end{bmatrix} \quad \mathbf{X} = \begin{bmatrix} (\mathbf{x}^{(1)})^T \\ (\mathbf{x}^{(2)})^T \\ \vdots \\ (\mathbf{x}^{(m)})^T \end{bmatrix} = \begin{bmatrix} 50962 & 72 & 85 & 13 \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

- m 是训练数据集上的实例数。

机器学习系统的类型

❑ 基于模型的学习实例：金钱能否让人更快乐？

➤ 例如：选择多元线性回归模型

($\mathbf{x}_{\text{国家}} = \{\text{GDP, 就业率, 健康, 空气污染}\}$)

- 性能指标：

$$RMSE(X, h) = \sqrt{\frac{1}{m} \sum_{i=1}^m \left(h(\mathbf{x}^{(i)}) - y^{(i)} \right)^2} \propto \|X \cdot \boldsymbol{\theta} - \mathbf{y}\|_2$$

- h ：系统的预测函数，也称为假设（hypothesis）。
- $y^{(i)}$ ：真实值（ground truth）
- $\hat{y}^i$ ：预测值（predicted value）

机器学习系统的类型

□ 基于模型的学习一般流程：

- 研究**数据**
- 选择**模型**
- 使用训练数据进行**训练**（使用学习算法搜索模型参数值，最小化成本函数）
- 应用模型对新实例进行**预测**

机器学习的主要挑战

- “坏数据”
- “坏算法”

机器学习的主要挑战

❑ “坏数据”

➤ 训练数据的数量不足




Figure 1-20. The importance of data versus algorithms⁹

机器学习的主要挑战

❑ “坏数据”

➤ 训练数据不具代表性：采样偏差




Figure 1-21. A more representative training sample

机器学习的主要挑战

❑ “坏数据”

➤ 低质量数据：训练数据满是错误、异常值和噪声

- 数据清理非常必要

➤ 无关特征

- 训练数据：足够多的相关特征，以及较少的无关特征，系统才能够学习好！
- 特征选取：从现有特征中选择最有用的特征进行训练
- 特征提取：将现有特征进行整合，产生更有用的特征（如降维算法）
- 收集新数据创建新特征

机器学习的主要挑战

❑ “坏数据”

➤ 过拟合训练数据 (**Overfitting**)

- 指模型在训练数据上表现良好，但是泛化时却不尽如人意。
- 当模型相对训练数据过于复杂时，会发生过拟合。
- 解决方法：简化模型；增加训练数据；对模型进行正则化




Figure 1-22. Overfitting the training data

机器学习的主要挑战

□ “坏数据”

➤ 欠拟合训练数据 (**Underfitting**)

- 模型过于简单
- 解决方法：
 - ✓ 选择更强大的模型；
 - ✓ 给学习算法提供更好的特征集（特征工程）；
 - ✓ 减少模型的约束（减少正则化参数）。

本章小结

基本术语和概念：

- 训练数据集、样本、特征、标签、真实值
- 假设空间、版本空间
- 归纳偏好、奥卡姆剃刀原理、NFL定理
- 过拟合、欠拟合
- 有监督学习（分类、回归）、无监督学习、强化学习

机器学习形式化描述及一般流程：

- 输入：特性向量
- 模型： $f(X)$ 、 $P(Y|X)$
- 输出：损失函数

本章小结

- 基本术语和概念（1.2, 1.3, 1.4）
- 《机器学习实战》第1章。
- 《动手学深度学习》第1章。
- 安装机器学习相关软件工具：
 - ✓ Anaconda + Jupyter/PyCharm
- 复习相关数学知识（线性代数，微积分，概率论）
 - ✓ 《机器学习》附录：**A**矩阵、**B**优化、**C**概率分布

前往第二站.....

