



二、模型评估与选择

温铁祥
健康与环境工程学院



典型的机器学习过程



然而, 我们手上没有 unseen instance,

泛化误差 vs. 经验误差

经验误差：在训练集上的误差，亦称“训练误差”

泛化误差：在“未来”样本上的误差

- 泛化误差越小越好
- 经验误差是否越小越好？

NO! 因为会出现“**过拟合**” (overfitting)

过拟合(overfitting)

vs. 欠拟合(underfitting)

例：数据拟合

给定训练数据集：


$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

多项式函数拟合数据：

$$f_M(x, \mathbf{w}) = w_0 + w_1 x^1 + \dots + w_M x^M = \sum_{j=0}^M w_j x^j$$





经验误差最小：

$$L(\mathbf{w}) = \frac{1}{2} \sum_{i=1}^N (f_M(\mathbf{x}_i, \mathbf{w}) - y_i)^2$$






过拟合(overfitting)

vs. 欠拟合(underfitting)



三个关键问题:

- 如何获得测试结果?  评估方法
- 如何评估性能优劣?  性能度量
- 如何判断实质差别?  比较检验

评估方法


关键：怎么获得“测试集” (testing set) ？

测试集应该与训练集“互斥”： $D = S \cup T, S \cap T = \emptyset$

常见方法：

- ❑ 留出法 (hold-out)
- ❑ 交叉验证法 (cross validation)
- ❑ 自助法 (bootstrap)


留出法 (hold-out)




注意：

- 保持数据分布一致性（例如：分层采样）
- 测试集不能太大、不能太小 (例如：10%~30%)
- 多次重复划分 (例如：100次随机划分)

k -折交叉验证法 (k -fold cross validation)



$$D = D_1 \cup D_2 \cup \dots \cup D_k, D_i \cap D_j = \emptyset$$



若 $k = m$, 则得到“留一法”
(leave-one-out, LOO)





图 2.2 10 折交叉验证示意图

例：5次10折交叉验证，共进行 50 次训练/测试。



自助法 (bootstrapping)

基于“自助采样” (bootstrap sampling)

亦称“有放回采样”、“可重复采样”



D (m个样本)



D' (m个样本)

约有 36.8% 的样本不出现

↓ $\lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m \mapsto \frac{1}{e} \approx 0.368$

- 训练集与原样本集同规模
- 数据分布有所改变

“包外估计” (out-of-bag estimation)

D' : 用于训练集; $D \setminus D'$: 用于测试集。

“调参”（parameter tuning）与最终模型

模型的参数：一般由学习确定

算法的参数：一般由人工设定，亦称“**超参数**”
(hyper-parameter)


调参过程相似：先产生若干模型，然后基于某种评估方法进行选择

参数调得好不好对性能往往对最终性能有关键影响

区别：训练集 vs. **验证集** (validation set) vs. 测试集

算法参数选定后，要用“训练集+验证集”重新训练最终模型

“调参”（parameter tuning）与最终模型



k -折交叉验证法 (k -fold cross validation)







图 2.2 10 折交叉验证示意图

三个关键问题:

- 如何获得测试结果?  评估方法
- 如何评估性能优劣?  性能度量
- 如何判断实质差别?  比较检验

性能度量

性能度量(performance measure)是衡量模型泛化能力的评价标准，反映了任务需求

使用不同的性能度量往往会导致不同的评判结果

什么样的模型是“好”的，不仅取决于算法和数据，还取决于任务需求

□ 回归(regression) 任务常用均方误差 MSE:

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2$$

错误率 vs. 精度

□ 错误率 (error rate) :

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) \neq y_i)$$

□ 精度 (accuracy) :

$$\begin{aligned} \text{acc}(f; D) &= \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) = y_i) \\ &= 1 - E(f; D) . \end{aligned}$$

查准率 (Precision) vs. 查全率 (Recall)


表 2.1 分类结果混淆矩阵 (confusion matrix)

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

□ 查准率:
$$P = \frac{TP}{TP + FP}$$

□ 查全率:
$$R = \frac{TP}{TP + FN}$$

查准率 (Precision) vs. 查全率 (Recall)



查准率 (Precision) vs. 查全率 (Recall)




Figure 3-3. In this precision/recall trade-off, images are ranked by their classifier score, and those above the chosen decision threshold are considered positive; the higher the threshold, the lower the recall, but (in general) the higher the precision

e.g. $f(\text{5}) = \text{score.}$

查准率 (Precision) vs. 查全率 (Recall)







Figure 3-4. Precision and recall versus the decision threshold

查准率 (Precision) vs. 查全率 (Recall)



P-R曲线, BEP

基于学习器的PR曲线，进行性能比较。



PR图:

- 学习器 A 优于 学习器 C
- 学习器 B 优于 学习器 C
- 学习器 A ?? 学习器 B

BEP:

- 学习器 A 优于 学习器 B
- 学习器 A 优于 学习器 C
- 学习器 B 优于 学习器 C

F1 score

比 BEP 更常用的 F1 度量:

$$F_1 = \frac{2}{\frac{1}{\text{precision}} + \frac{1}{\text{recall}}} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} = \frac{TP}{TP + \frac{FN+FP}{2}}$$

若对查准率/查全率有不同偏好:

$$\frac{1}{F_\beta} = \frac{1}{1 + \beta^2} \left(\frac{1}{P} + \frac{\beta^2}{R} \right) \quad \Rightarrow \quad F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

$\beta > 1$ 时查全率有更大影响; $\beta < 1$ 时查准率有更大影响

- 对商品推荐系统, P、R哪个更重要?
- 对疾病筛查系统, P、R哪个更重要?

宏XX vs. 微XX

若能得到多个混淆矩阵:

(例如多次训练/测试的结果, 多分类的两两混淆矩阵)

宏(**macro-**)查准率、查全率、F1

$$\text{macro-}P = \frac{1}{n} \sum_{i=1}^n P_i ,$$

$$\text{macro-}R = \frac{1}{n} \sum_{i=1}^n R_i ,$$

$$\text{macro-}F1 = \frac{2 \times \text{macro-}P \times \text{macro-}R}{\text{macro-}P + \text{macro-}R} .$$

微(**micro-**)查准率、查全率、F1


$$\text{micro-}P = \frac{\overline{TP}}{\overline{TP} + \overline{FP}} ,$$

$$\text{micro-}R = \frac{\overline{TP}}{\overline{TP} + \overline{FN}} ,$$

$$\text{micro-}F1 = \frac{2 \times \text{micro-}P \times \text{micro-}R}{\text{micro-}P + \text{micro-}R} .$$

ROC曲线

-- 受试者工作特征曲线



ROC, AUC

ROC曲线的绘制:

假设我们已经训练得到一个学习器 $f(\mathbf{x})$, 现在用该学习器对8个测试样本（4个正例, 4个反例, 即 $m^+ = m^- = 4$ ）进行预测, 测试结果为: $(\mathbf{x}_1, 0.77, +)$, $(\mathbf{x}_2, 0.15, -)$, $(\mathbf{x}_3, 0.33, -)$, $(\mathbf{x}_4, 0.47, +)$, $(\mathbf{x}_5, 0.23, +)$, $(\mathbf{x}_6, 0.58, +)$, $(\mathbf{x}_7, 0.47, -)$, $(\mathbf{x}_8, 0.62, -)$.

解:

1) 对所有测试样例按学习器给出的预测结果进行排序

$(\mathbf{x}_1, 0.77, +)$

$(\mathbf{x}_8, 0.62, -)$

$(\mathbf{x}_6, 0.58, +)$

$(\mathbf{x}_4, 0.47, +)$

$(\mathbf{x}_7, 0.47, -)$

$(\mathbf{x}_3, 0.33, -)$

$(\mathbf{x}_5, 0.23, +)$

$(\mathbf{x}_2, 0.15, -)$

ROC, AUC

解：

2) 将分类阈值设为1.0，显然此时 $TP=0$ ，因此 $TPR=FPR=0$ ，在(0,0)处记一个点。

3) 接着依次将分类阈值从大到小设为每个样本的预测值，即0.77, 0.62, 0.58, 0.47, 0.33, 0.23, 0.15，每次计算TPR、FPR：设前一个标记点为(x,y)，当前若为真正例，则对应标记点坐标为 $(x, y + \frac{1}{m^+})$ ，若为假正例，则为 $(x + \frac{1}{m^-}, y)$ 。

$(x_1, 0.77, +)$

$(x_8, 0.62, -)$

$(x_6, 0.58, +)$

$(x_4, 0.47, +)$

$(x_7, 0.47, -)$


$(x_3, 0.33, -)$

$(x_5, 0.23, +)$

$(x_2, 0.15, -)$

ROC, AUC

	Threshold
1.0	←
$(x_1, 0.77, +)$	←
$(x_8, 0.62, -)$	←
$(x_6, 0.58, +)$	←
$(x_4, 0.47, +)$	←
$(x_7, 0.47, -)$	←
$(x_3, 0.33, -)$	←
$(x_5, 0.23, +)$	←
$(x_2, 0.15, -)$	←




AUC: Area Under the ROC Curve

$$AUC = \frac{1}{2} \sum_{i=1}^{m-1} (x_{i+1} - x_i)(y_i + y_{i+1})$$

The bigger, the better

ROC, AUC



AUC: Area Under the ROC Curve

The bigger, the better

非均等代价

犯不同的错误往往会造成不同的损失

此时需考虑“非均等代价”
(unequal cost)



表 2.2 二分类代价矩阵

真实类别	预测类别	
	第 0 类	第 1 类
第 0 类	0	$cost_{01}$
第 1 类	$cost_{10}$	0

□ 代价敏感(cost-sensitive)错误率:

$$E(f; D; cost) = \frac{1}{m} \left(\sum_{\mathbf{x}_i \in D^+} \mathbb{I}(f(\mathbf{x}_i) \neq y_i) \times cost_{01} + \sum_{\mathbf{x}_i \in D^-} \mathbb{I}(f(\mathbf{x}_i) \neq y_i) \times cost_{10} \right)$$

三个关键问题:

- 如何获得测试结果?  评估方法
- 如何评估性能优劣?  性能度量
- 如何判断实质差别?  比较检验

常用方法

统计假设检验 (hypothesis test) 为学习器性能比较提供了重要依据

□ 两学习器比较

➤ 交叉验证 t 检验 (基于成对 t 检验)

k 折交叉验证; 5x2交叉验证

➤ McNemar 检验 (基于列联表, 卡方检验)

□ 多学习器比较

➤ Friedman + Nemenyi

- Friedman检验 (基于序值, F检验; 判断”是否都相同”)


- Nemenyi 后续检验 (基于序值, 进一步判断两两差别)



统计显著性

两学习器比较

□ k 折交叉验证 t 检验 (基于成对 t 检验)



若两个学习器 (A 和 B) 性能相同, 则 Δ_i 差值均值应为零。
根据 Δ_i 差值对 “学习器 A 和 B 性能相同” 这个假设做 t 检验。

两学习器比较

□ k 折交叉验证 t 检验 (基于成对 t 检验)

- α : 显著度 (significance)
- $1-\alpha$: 置信水平 (confidence)

$$\tau_t = \left| \frac{\sqrt{k}\mu}{\sigma} \right| \quad (2.31)$$





图 2.7 t 分布示意图($k = 10$)

表 2.3 双边 t 检验的常用临界值

α	k				
	2	5	10	20	30
0.05	12.706	2.776	2.262	2.093	2.045
0.10	6.314	2.132	1.833	1.729	1.699

多学习器 (>2) 比较

□ Friedman检验与Nemenyi后续检验



数据集	算法 A	算法 B	算法 C
D_1	1	2	3
D_2	1	2.5	2.5
D_3	1	2	3
D_4	1	2	3
平均序值	1	2.125	2.875

多学习器 (>2) 比较

□ Friedman检验与Nemenyi后续检验

- N: 数据集个数
- k: 算法个数
- r_i : 第i个算法的平均序值

表 2.5 算法比较序值表

数据集 N	算法 A	算法 B	算法 C	k
D_1	1	2	3	
D_2	1	2.5	2.5	
D_3	1	2	3	
D_4	1	2	3	
平均序值 r_i	1	2.125	2.875	

多学习器 (>2) 比较

□ Friedman检验与Nemenyi后续检验

表 2.5 算法比较序值表

数据集 N	算法 A	算法 B	算法 C k
D_1	1	2	3
D_2	1	2.5	2.5
D_3	1	2	3
D_4	1	2	3
平均序值 $\bar{r}_i$	1	2.125	2.875

$$\begin{aligned}\tau_{\chi^2} &= \frac{k-1}{k} \cdot \frac{12N}{k^2-1} \sum_{i=1}^k \left(r_i - \frac{k+1}{2} \right)^2 \\ &= \frac{12N}{k(k+1)} \left(\sum_{i=1}^k r_i^2 - \frac{k(k+1)^2}{4} \right)\end{aligned}$$



Friedman检验：基于序值，F检验; 判断”是否都相同”。

表 2.6 F 检验的常用临界值

$\alpha = 0.05$									
数据集	算法个数 k								
个数 N	2	3	4	5	6	7	8	9	10
4	10.128	5.143	3.863	3.259	2.901	2.661	2.488	2.355	2.250
5	7.709	4.459	3.490	3.007	2.711	2.508	2.359	2.244	2.153
8	5.591	3.739	3.072	2.714	2.485	2.324	2.203	2.109	2.032
10	5.117	3.555	2.960	2.634	2.422	2.272	2.159	2.070	1.998
15	4.600	3.340	2.827	2.537	2.346	2.209	2.104	2.022	1.955
20	4.381	3.245	2.766	2.492	2.310	2.179	2.079	2.000	1.935

$$\tau_F = \frac{(N-1)\tau_{\chi^2}}{N(k-1) - \tau_{\chi^2}},$$

=24.429

多学习器 (>2) 比较

□ Friedman检验与Nemenyi后续检验

表 2.5 算法比较序值表

数据集 N	算法 A	算法 B	算法 C	k
D_1	1	2	3	
D_2	1	2.5	2.5	
D_3	1	2	3	
D_4	1	2	3	
平均序值 $\bar{r}_i$	1	2.125	2.875	

若两个算法的平均序值之差超过了临界阈值CD，则以相应的置信度拒绝“两个算法性能相同”这一假设。



Nemenyi 后续检验：基于序值，进一步判断两两差别。

表 2.7 Nemenyi 检验中常用的 q_α 值

α	算法个数 k								
	2	3	4	5	6	7	8	9	10
0.05	1.960	2.344	2.569	2.728	2.850	2.949	3.031	3.102	3.164
0.1	1.645	2.052	2.291	2.459	2.589	2.693	2.780	2.855	2.920

平均序值差别的
临界阈值CD:

$$CD = q_\alpha \sqrt{\frac{k(k+1)}{6N}},$$

=1.657

多学习器 (>2) 比较

横轴为平均序值，每个算法圆点为其平均序值，线段为临界阈值的大小





图 2.8 Friedman 检验图

若两个算法有交叠 (A 和 B), 则说明没有显著差别;
否则有显著差别 (A 和 C), 算法 A 显著优于算法 C

“误差”包含了哪些因素？

换言之，从机器学习的角度看，

“误差”从何而来？

The bottom of the slide features three horizontal bars of different colors: a thin light pink bar, a slightly thicker medium pink bar, and a thick teal bar at the very bottom.



Leslie Valiant
(莱斯利 维利昂特)
(1949-)
2010年图灵奖

计算学习理论

Computational learning theory

PAC (Probably Approximately Correct)

learning model

[Valiant, 1984]

$$P(|f(\mathbf{x}) - y| \leq \epsilon) \geq 1 - \delta$$

→ 第12章

机器学习 $\Rightarrow$ “概率近似正确”

偏差-方差分解 (bias-variance decomposition)

对回归任务，泛化误差可通过“偏差-方差分解”拆解为：

$$E(f; D) = \underbrace{bias^2(\mathbf{x})}_{\text{red}} + \underbrace{var(\mathbf{x})}_{\text{blue}} + \underbrace{\varepsilon^2}_{\text{green}}$$

输出的期望与
真实输出的差别

$$bias^2(\mathbf{x}) = (\bar{f}(\mathbf{x}) - y)^2$$

同样大小的训练集
的变动，所导致的
性能变化

$$var(\mathbf{x}) = \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right]$$

训练样本的标记与
真实标记有区别

表达了当前任务上任何学习算法
所能达到的期望泛化误差下界

$$\varepsilon^2 = \mathbb{E}_D \left[(y_D - y)^2 \right]$$

泛化性能是由学习算法的能力、数据的充分性以及学习任务本身的难度共同决定


偏差-方差分解 (bias-variance decomposition)

$$E(f; D) = \underbrace{bias^2(\mathbf{x})}_{\text{red arrow}} + \underbrace{var(\mathbf{x})}_{\text{blue arrow}} + \underbrace{\varepsilon^2}_{\text{green arrow}}$$

$$bias^2(\mathbf{x}) = (\bar{f}(\mathbf{x}) - y)^2$$

$$var(\mathbf{x}) = \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right]$$

$$\varepsilon^2 = \mathbb{E}_D \left[(y_D - y)^2 \right]$$



偏差-方差窘境 (bias-variance dilemma)

一般而言，偏差与方差存在冲突：

- 训练不足时，学习器拟合能力不强，偏差主导
- 随着训练程度加深，学习器拟合能力逐渐增强，方差逐渐主导
- 训练充足后，学习器的拟合能力很强，方差主导




图 2.9 泛化误差与偏差、方差的关系示意图

本章小结

- 训练误差、泛化误差、过拟合、欠拟合
- 模型评估
 - 留出法、**k折交叉验证法**、自助法
- 性能度量
 - 错误率、精度
 - 混淆矩阵、查准率、查全率、**F1分数**、**P-R曲线**、**ROC曲线**、代价矩阵
- 模型比较
 - 交叉验证**t检验**、**Friedman检验**与**Nemenyi后续检验**
- 模型误差分析
 - 泛化误差=偏差+方差+噪声

本章小结

- ❑ 同步学习 《机器学习实战》 第2、3章内容
- ❑ 同步学习 《动手学深度学习》 第2章内容
- ❑ 本章作业：
 - P48, 2.8
 - 假设某机器学习模型的真实类别和预测类别如下表所示， 求它的混淆矩阵、 错误率、 精度、 查准率、 查全率、 F1 score。

样本 序号	1	2	3	4	5	6	7	8	9	10
真实 类别	1	1	1	-1	-1	-1	1	1	1	-1
预测 类别	1	-1	1	-1	-1	1	1	1	-1	-1

本章小结

- 假设我们已经训练得到一个学习器 $f(\mathbf{x})$ ，现在用该学习器对10个测试样本（5个正例，5个反例）进行预测，测试结果如下表，要求绘制出该学习器的ROC曲线。

样本 序号	1	2	3	4	5	6	7	8	9	10
真实 类别	1	1	-1	-1	1	1	1	-1	-1	-1
预测 概率	0.85	0.75	0.15	0.34	0.46	0.28	0.57	0.46	0.28	0.62

前往第三站.....

