

四、决策树

温铁祥
健康与环境工程学院
wentiexiang@sztu.edu.cn


决策树模型 (decision tree)

决策树基于“树”结构进行决策

- ❑ 每个“**内部结点**”对应于某个属性上的“测试”(test)
- ❑ 每个**分支**对应于该测试的一种可能结果（即该属性的某个取值）
- ❑ 每个“**叶结点**”对应于一个“预测结果”

学习过程：通过对训练样本的分析来确定“划分属性”（即内部结点所对应的属性）

预测过程：将测试示例从根结点开始，沿着划分属性所构成的“判定测试序列”下行，直到叶结点



$if (色泽 = "青绿" \wedge 根蒂 = "蜷缩" \wedge 敲声 = "浊响") \rightarrow "好瓜"$

图 4.1 西瓜问题的一棵决策树

决策树简史

- 第一个决策树算法：CLS (Concept Learning System)
[E. B. Hunt, J. Marin, and P. T. Stone's book "*Experiments in Induction*" published by Academic Press in 1966]
- 使决策树受到关注、成为机器学习主流技术的算法：ID3
[J. R. Quinlan's paper in a book "*Expert Systems in the Micro Electronic Age*" edited by D. Michie, published by Edinburgh University Press in 1979]
- 最常用的决策树算法：C4.5
[J. R. Quinlan's book "*C4.5: Programs for Machine Learning*" published by Morgan Kaufmann in 1993]



决策树简史(con't)

- 可以用于回归任务的决策树算法：CART (Classification and Regression Tree)

[L. Breiman, J. H. Friedman, R. A. Olshen, and C. J. Stone's book "Classification and Regression Trees" published by Wadsworth in 1984]

- 基于决策树的最强大算法：RF (Random Forest)

[L. Breiman's MLJ'01 paper "Random Forest"]

这是一种“集成学习”方法 → 第 8 章

基本流程

策略：“分而治之” (divide-and-conquer)

自根至叶的递归过程

在每个中间结点寻找一个“划分” (split or test) 属性

三种停止条件：

- (1) 当前结点包含的样本全属于同一类别，无需划分；
- (2) 当前属性集为空, 或是所有样本在所有属性上取值相同，无法划分；
- (3) 当前结点包含的样本集合为空，不能划分。

基本算法

输入: 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$;
属性集 $A = \{a_1, a_2, \dots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

1: 生成结点 node;

2: if D 中样本全属于同一类别 C then

3: 将 node 标记为 C 类叶结点; return

4: end if

递归返回,
情形(1)

5: if $A = \emptyset$ OR D 中样本在 A 上取值相同 then

6: 将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; return

7: end if

递归返回,
情形(2)

8: 从 A 中选择最优划分属性 a_* ;

利用当前结点的后验分布

9: for a_* 的每一个值 a_*^v do

10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;

11: if D_v 为空 then

12: 将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; return

13: else

14: 以 TreeGenerate($D_v, A \setminus \{a_*\}$) 为分支结点

将父结点的样本分布作为
当前结点的先验分布

15: end if

16: end for

递归返回,
情形(3)

决策树算法的核心

递归过程

输出: 以 node 为根结点的一棵决策树

信息增益 (information gain)

信息熵 (entropy) 是度量样本集合“**纯度**”最常用的一种指标

假定当前样本集合 D 中第 k 类样本所占的比例为 p_k ，则 D 的**信息熵**定义为

$$Ent(D) = - \sum_{k=1}^{|Y|} p_k \log_2(p_k)$$

Ent(D) 的值越小，则**D**的纯度越高

约定：如果 $p = 0$ ，则 $p \log_2(p) = 0$ 。

$Ent(D)$ 的最小值：0，此时 D 只有一类

最大值： $\log_2(|Y|)$ ，此时 D 每个样本都是一类

离散属性 a 的取值: $\{a^1, a^2, \dots, a^V\}$

D^v : D 中在 a 上取值 = a^v 的样本集合

以属性 a 对数据集 D 进行划分所获得的信息增益为:

$$\text{Gain}(D, a) = \underbrace{\text{Ent}(D)}_{\text{划分前的信息熵}} - \sum_{v=1}^V \underbrace{\frac{|D^v|}{|D|}}_{\text{第 } v \text{ 个分支的权重, 样本越多越重要}} \underbrace{\text{Ent}(D^v)}_{\text{划分后的信息熵}}$$

一个例子

表 4.1 西瓜数据集 2.0

			编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
D Pr ob	是	否	1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
			2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
			3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
			4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
			5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
			6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
			7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
			8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
	$\frac{8}{17}$	$\frac{9}{17}$	9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
			10	青绿	硬挺	清脆	清晰	平坦	软粘	否
			11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
			12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
			13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
			14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
			15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
			16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
			17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

$$Ent(D) = -\frac{8}{17}\log_2\left(\frac{8}{17}\right) - \frac{9}{17}\log_2\left(\frac{9}{17}\right) = 0.998$$

一个例子 (续)

■以属性“色泽”为例，其对应的3个数据子集分别为 D^1 (色泽=青绿)， D^2 (色泽=乌黑)， D^3 (色泽=浅白)

■子集 D^1 包含编号为{1, 4, 6, 10, 13, 17}的6个样例，其中正例占 $p_1 = \frac{3}{6}$ ，反例占 $p_2 = \frac{3}{6}$ ， D^2 、 D^3 同理，3个节点的信息熵为：

$$\text{Ent}(D^1) = -(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6}) = 1.000$$

$$\text{Ent}(D^2) = -(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}) = 0.918$$

$$\text{Ent}(D^3) = -(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}) = 0.722$$

■属性“色泽”的信息增益为

$$\begin{aligned} \text{Gain}(D, \text{色泽}) &= \text{Ent}(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - (\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722) \\ &= 0.109 \end{aligned}$$

一个例子 (续)

□ 类似的，其他属性的信息增益为

$$\text{Gain}(D, \text{根蒂}) = 0.143$$


$$\text{Gain}(D, \text{纹理}) = 0.381$$

$$\text{Gain}(D, \text{触感}) = 0.006$$

$$\text{Gain}(D, \text{敲声}) = 0.141$$

$$\text{Gain}(D, \text{脐部}) = 0.289$$

□ 显然，属性“纹理”的信息增益最大，其被选为划分属性



编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

□对“纹理=清晰”节点进行递归划分，根据信息增益最大原则，选出“根蒂”属性（注意：此时纹理特征不再作为候选划分属性！）


编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

□对“纹理=稍糊”节点进行递归划分，根据信息增益最大原则，选出“触感”属性（注意：此时纹理特征不再作为候选划分属性！）

□对“纹理=模糊”节点，由于属于相同类别，该节点不在递归划分，并标记叶子节点。

一个例子 (续)

对每个分支结点做进一步划分，最终得到决策树



信息增益：对可取值数目较多的属性有所偏好

有明显弱点，例如：考虑将“编号”作为一个属性

增益率：

$$\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$$

其中

$$\text{IV}(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

属性 a 的可能取值数目越多 (即 V 越大), 则 $\text{IV}(a)$ 的值通常就越大

缺点是：对取值数目少的属性有偏好

启发式：先从候选划分属性中找出信息增益高于平均水平的，再从中选取增益率最高的

$$\begin{aligned}\text{Gini}(D) &= \sum_{k=1}^{|\mathcal{Y}|} \sum_{k' \neq k} p_k p_{k'} \\ &= 1 - \sum_{k=1}^{|\mathcal{Y}|} p_k^2.\end{aligned}$$

反映了从 D 中随机抽取两个样例，其类别标记不一致的概率

$\text{Gini}(D)$ 越小，数据集 D 的纯度越高

属性 a 的基尼指数:
$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

在候选属性集合中，选取那个使划分后基尼指数最小的属性

划分选择 vs. 剪枝

研究表明: 划分选择的各种准则虽然对决策树的尺寸有较大影响, 但对泛化性能的影响很有限

例如信息增益与基尼指数产生的结果, 仅在约 2% 的情况下不同

剪枝方法和程度对决策树泛化性能的影响更为显著

在数据带噪时甚至可能将泛化性能提升 25%

剪枝 (pruning) 是决策树对付“过拟合”的主要手段!

剪枝

为了尽可能正确分类训练样本，有可能造成分支过多 → 过拟合
可通过主动去掉一些分支来降低过拟合的风险

基本策略：

- 预剪枝 (pre-pruning): 提前终止某些分支的生长
- 后剪枝 (post-pruning): 生成一棵完全树，再“回头”剪枝

剪枝过程中需评估剪枝前后决策树的优劣 → 第 2 章

现在我们假定使用“留出法”：预留一部分数据作为验证集

数据集


表 4.2 西瓜数据集 2.0 划分出的训练集(双线上部)与验证集(双线下部)

训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否



预剪枝——

不划分：根节点被标记为叶节点，其类别标记为训练样例最多的类别

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	模型	划分前 训练集
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是	是	
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是	是	
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是	是	
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是	是	
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是	是	
10	青绿	硬挺	清脆	清晰	平坦	软粘	否	是	
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否	是	
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否	是	
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否	是	
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否	是	

验证集精度

“脐部=?” 划分前: 3 / 7
=42.9%

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	正确?	划分前 验证集
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是	✓	
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是	✓	
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是	✓	
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否	×	
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否	×	
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否	×	
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否	×	

预剪枝—

划分后：按脐部
属性进行划分

验证集精度
“脐部=?”

划分前：3 / 7 =42.9%

划分后：5 / 7 =71.4%

结论：
划分，
不剪枝

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	模型	划分后 训练集
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是	是	
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是	是	
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是	是	
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否	是	
10	青绿	硬挺	清脆	清晰	平坦	软粘	否	否	
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否	否	
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是	是	
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是	是	
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否	是	
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否	是	

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	正确?	划分后 验证集
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是	✓	
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是	✓	
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否	✗	
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否	✓	
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否	✓	
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是	✓	
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否	✗	


预剪枝 (续)

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1: 若划分, 根据结点 ②, ③, ④ 的训练样例, 将这3个结点分别标记为“好瓜”、“好瓜”、“坏瓜”。此时, 验证集中编号为 {4, 5, 8, 11, 12} 的样例被划分正确, 验证集精度为 $\frac{5}{7} \times 100\% = 71.4\%$

验证集精度




“脐部=?” 划分前: 42.9%
划分后: 71.4%
预剪枝决策: 划分

预剪枝 (续)

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

对结点②,③,④分别进行剪枝判断, 结点②,③都禁止划分, 结点④本身为叶子结点。最终得到仅有一层划分的决策树, 称为“决策树桩”(decision stump)



验证集精度

“脐部=?” 划分前: 42.9%
划分后: 71.4%

预剪枝决策: 划分

验证集精度


“色泽=?” 划分前: 71.4%
划分后: 57.1%

预剪枝决策: 禁止划分


验证集精度

“根蒂=?” 划分前: 71.4%
划分后: 71.4%

预剪枝决策: 禁止划分



预剪枝




□ 过/欠拟合风险:

- 过拟合风险降低，欠拟合风险增加

□ 时间开销:


- 训练/测试时间开销降低

后剪枝




后剪枝 (续)

首先考虑结点⑥，若将其替换为叶结点，根据落在其上的训练样例{7, 15}将其标记为“好瓜”，测得验证集精度提高至 57.1%，于是决定剪枝



验证集精度
剪枝前: $3/7=42.9\%$
剪枝后: 57.1%
后剪枝决策: 剪枝


后剪枝



验证集精度
剪枝前: $3/7=42.9\%$

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	正确?	剪枝前 验证集
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是	✓	
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是	×	
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是	×	
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否	×	
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否	✓	
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否	✓	
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否	×	

后剪枝



验证集精度

剪枝前: $3/7=42.9\%$

剪枝后: $4/7=57.1\%$


后剪枝决策: 剪枝

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	正确?
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是	✓
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是	×
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是	✓
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否	×
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否	✓
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否	✓
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否	×

剪枝后
验证集

后剪枝 (续)


然后考虑结点⑤,若将其替换为叶结点,根据落在其上的训练样例{6,7,15} 将其标记为“好瓜”,测得验证集精度仍为 57.1%,可以不剪枝



验证集精度
剪枝前: 57.1%
剪枝后: 57.1%
后剪枝决策: 不剪枝

后剪枝 (续)


对结点②，若将其替换为叶结点，根据落在其上的训练样例 {1, 2, 3, 14}，将其标记为“好瓜”，测得验证集精度提升至 71.4%，决定剪枝



验证集精度
剪枝前: 57.1%
剪枝后: 71.4%
后剪枝决策: 剪枝


后剪枝 (续)

对结点③和①，先后替换为叶结点，均未测得验证集精度提升，
于是不剪枝



后剪枝 (续)

最终，后剪枝得到的决策树：



□ 过/欠拟合风险：

- 过拟合风险降低，欠拟合风险基本不变

□ 时间开销：

- 训练时间开销增加，测试时间开销降低

预剪枝 vs. 后剪枝

□ 过/欠拟合风险:

- 预剪枝: 过拟合风险降低, 欠拟合风险增加
- 后剪枝: 过拟合风险降低, 欠拟合风险基本不变

□ 时间开销:

- 预剪枝: 训练时间开销降低, 测试时间开销降低
- 后剪枝: 训练时间开销增加, 测试时间开销降低

□ 泛化性能: 后剪枝 通常优于 预剪枝

连续值

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.46	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.36	0.37	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否


连续值

基本思路：连续属性离散化

连续变量 $x_1 < x_2 < \dots < x_n$ ，取区间中点： $\frac{x_i + x_{i+1}}{2}$ 作为属性值。

常见做法：二分法 (bi-partition)

- n 个属性值可形成 $n - 1$ 个候选划分
- 然后即可将它们当做 $n - 1$ 个离散属性值处理



注：对连续属性，该属性还可作为后代节点的划分属性。

缺失值

现实应用中，经常会遇到属性值“缺失”(missing)现象

仅使用无缺失的样例？ → 对数据的极大浪费

使用带缺失值的样例，需解决：

Q1：如何进行划分属性选择？

Q2：给定划分属性，若样本在该属性上的值缺失，如何进行划分？

基本思路：样本赋权，权重划分

一个例子

仅通过无缺失值的
样例来判断划
分属性的优劣

每个样本 x
关联一个权重 w_x

学习开始时，根结点包
含样例集 D 中全部17个
样例，权重均为 1

表 4.4 西瓜数据集 2.0a

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	—	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	—	是
3	乌黑	蜷缩	—	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	—	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	—	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	—	稍凹	硬滑	是
9	乌黑	—	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	—	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	—	否
12	浅白	蜷缩	—	模糊	平坦	软粘	否
13	—	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	—	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	—	沉闷	稍糊	稍凹	硬滑	否

以属性“色泽”为例，该属性上无缺失值的样例子集 $\tilde{D}$ 包含 14 个样例，
信息熵为

$$\text{Ent}(\tilde{D}) = - \sum_{k=1}^2 \tilde{p}_k \log_2 \tilde{p}_k = - \left(\frac{6}{14} \log_2 \frac{6}{14} + \frac{8}{14} \log_2 \frac{8}{14} \right) = 0.985$$

无缺失值样例中第 k 类所占比例（式4.10）

一个例子

令 $\tilde{D}^1, \tilde{D}^2, \tilde{D}^3$ 分别表示在属性“色泽”上取值为“青绿”“乌黑”以及“浅白”的样本子集，有

$$\begin{aligned}\text{Ent}(\tilde{D}^1) &= -\left(\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4}\right) = 1.000 & \text{Ent}(\tilde{D}^2) &= -\left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}\right) = 0.918 \\ \text{Ent}(\tilde{D}^3) &= -\left(\frac{0}{4} \log_2 \frac{0}{4} + \frac{4}{4} \log_2 \frac{4}{4}\right) = 0.000\end{aligned}$$

因此，样本子集 $\tilde{D}$ 上属性“色泽”的信息增益为

$$\begin{aligned}\text{Gain}(\tilde{D}, \text{色泽}) &= \text{Ent}(\tilde{D}) - \sum_{v=1}^3 \tilde{r}_v \text{Ent}(\tilde{D}^v) && \begin{array}{l} \text{无缺失值样例中属性 } a \\ \text{取值为 } v \text{ 的占比 (式4.11)} \end{array} \\ &= 0.985 - \left(\frac{4}{14} \times 1.000 + \frac{6}{14} \times 0.918 + \frac{4}{14} \times 0.000\right) \\ &= 0.306\end{aligned}$$

于是，样本集 D 上属性“色泽”的信息增益为

$$\text{Gain}(D, \text{色泽}) = \rho \times \text{Gain}(\tilde{D}, \text{色泽}) = \frac{14}{17} \times 0.306 = 0.252$$

区别： 无缺失值样例占比（式4.9）

一个例子

类似地可计算出所有属性在数据集上的信息增益

$\text{Gain}(D, \text{色泽}) = 0.252$

$\text{Gain}(D, \text{敲声}) = 0.145$

$\text{Gain}(D, \text{脐部}) = 0.289$

$\text{Gain}(D, \text{根蒂}) = 0.171$

$\text{Gain}(D, \text{纹理}) = 0.424$

$\text{Gain}(D, \text{触感}) = 0.006$

进入“纹理=清晰”分支

进入“纹理=稍糊”分支

进入“纹理=模糊”分支

样本权重在各子结点仍为1

在“纹理”上出现缺失值，
样本 8, 10 同时进入三个
分支，三支上的权重分
别为 7/15，5/15，3/15



编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	-	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	-	是
3	乌黑	蜷缩	-	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	-	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	-	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	-	稍凹	硬滑	是
9	乌黑	-	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	-	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	-	否
12	浅白	蜷缩	-	模糊	平坦	软粘	否
13	-	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	-	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	-	沉闷	稍糊	稍凹	硬滑	否

权重划分

轴平行划分


单变量决策树：在每个非叶结点仅考虑一个划分属性

产生“轴平行”分类面



轴平行 vs. 倾斜

当学习任务所对应的分类边界很复杂时，需要非常多段划分才能获得较好的近似





能否产生这样的分类边界？

多变量(multivariate)决策树

多变量决策树：每个非叶结点不仅考虑一个属性

例如“**斜决策树**” (oblique decision tree) 不是为每个非叶结点寻找最优划分属性，而是建立一个**线性分类器** $\sum_{i=1}^d w_i a_i = t$



更复杂的“混合决策树”甚至可以在结点嵌入神经网络或其他非线性模型

决策树常用软件包

- ❑ ID3, C4.5, C5.0

- <http://www.rulequest.com/Personal/>

- ❑ J4.8

- <http://www.cs.waikato.ac.nz/ml/weka/>

- ❑ `from sklearn.tree import DecisionTreeClassifier`

- ❑ `from sklearn.tree import DecisionTreeRegressor`

- ❑


决策树：分类

实例：鸢尾花分类

```
from sklearn.datasets import load_iris
from sklearn.tree import DecisionTreeClassifier
```

```
iris = load_iris()
X = iris.data[:, 2:] # petal length and width
y = iris.target
```

```
tree_clf = DecisionTreeClassifier(max_depth=2)
tree_clf.fit(X, y)
```



决策树：分类

实例：鸢尾花分类




Figure 6-2. Decision Tree decision boundaries

决策树：回归

决策树做回归分析：“分段线性”效果




Figure 6-5. Predictions of two Decision Tree regression models

$$J(k, t_k) = \frac{m_{\text{left}}}{m} \text{MSE}_{\text{left}} + \frac{m_{\text{right}}}{m} \text{MSE}_{\text{right}}$$

$$\text{where } \begin{cases} \text{MSE}_{\text{node}} = \sum_{i \in \text{node}} (\hat{y}_{\text{node}} - y^{(i)})^2 \\ \hat{y}_{\text{node}} = \frac{1}{m_{\text{node}}} \sum_{i \in \text{node}} y^{(i)} \end{cases}$$

前往第五站.....



本章小结

- 决策树模型
 - ID3: 信息增益
 - C4.5: 信息增益率
 - CART: Gini系数
- 避免过拟合
 - 剪枝: 预剪枝、后剪枝

本章作业

- 同步学习 《机器学习实战》第6章。
- 作业：分别用信息增益、Gini指数构造下表的决策树模型。

表 贷款申请
样本数据表

ID	年龄	有工作	有自己的房子	信贷情况	类别
1	青年	否	否	一般	否
2	青年	否	否	好	否
3	青年	是	否	好	是
4	青年	是	是	一般	是
5	青年	否	否	一般	否
6	中年	否	否	一般	否
7	中年	否	否	好	否
8	中年	是	是	好	是
9	中年	否	是	非常好	是
10	中年	否	是	非常好	是
11	老年	否	是	非常好	是
12	老年	否	是	好	是
13	老年	是	否	好	是
14	老年	是	否	非常好	是
15	老年	否	否	一般	否