



深圳技术大学
SHENZHEN TECHNOLOGY UNIVERSITY

机器学习 -数学预备知识

温铁祥

健康与环境工程学院

wentiexiang@sztu.edu.cn



信息论预备知识


□ 定义：事件包含的信息量大小

- “事件的发生使你惊讶的程度”
- 小概率事件：它发生的惊讶程度较大，所以有较大的信息量。
- 大概率事件：它发生的惊讶程度较小，所以有较小的信息量。

□ 信息量公式：

$$I(X = x_i) := \log \frac{1}{p_i} = -\log(p_i)$$

- 若以2为底：单位为比特 (bit) 。
- 例： $-\log_2(0.5) = 1 \text{ (bit)}$



□ 性质：

- 对独立事件A、B： $P(AB) = P(A)P(B)$ ；两个独立事件同时发生的信息量等于两个事件的信息量相加： $I(AB) = I(A) + I(B)$ 。

$$I(AB) = \log \frac{1}{P(AB)} = \log \frac{1}{P(A)P(B)} = -\log P(A) - \log P(B) = I(A) + I(B)$$

□ 定义：一个系统的信息量期望（**平均信息量**）。

- 基于概率模型去评估一个系统的不确定性。
- 熵越大，不确定性越大。
- 熵越小，不确定性越小。


□ 公式：
$$H(X) = E[I(X)] = \sum_{i=1}^n p_i I_i^p = -\sum_i p_i \log(p_i)$$

□ 性质：

- 1. $0 \leq H(p) \leq \log(n)$
- 2. 当X为0, 1分布时 (e.g. 二分类) ,

$$P(X=1) = p, \quad P(X=0) = 1-p, \quad 0 \leq p \leq 1$$

$$H(p) = -p \log p - (1-p) \log(1-p)$$



假设**真实概率分布**为 P ，**预测概率分布**为 Q

□ 定义：预测概率分布 Q 对真实概率分布 P 的平均信息量的估计，称为**交叉熵**。

□ 公式：

$$H(P, Q) := \sum_i p_i I_i^q = -\sum_i p_i \log(q_i)$$

□ 性质：

- 交叉熵的值 $\geq$ 熵的值（吉布斯Gibbs不等式）： $H(P, Q) \geq H(P)$ 。

若 $\sum_{i=1}^n p_i = \sum_{i=1}^n q_i = 1$ ，且 $p_i, q_i \in (0, 1]$ ，则有：

$-\sum_{i=1}^n p_i \log q_i \geq -\sum_{i=1}^n p_i \log p_i$ ，等号成立当且仅当 $p_i = q_i, \forall i$ 。

□ 性质:

- 预测概率分布与真实概率分布越接近, 交叉熵越小。

例1: 抛硬币

	正面	反面
真实概率分布 P	$P(X = 1) = 0.5$	$P(X = 0) = 0.5$
预测1概率分布 Q_1	$Q(X = 1) = 0.2$	$Q(X = 0) = 0.8$
预测2概率分布 Q_2	$Q(X = 1) = 0.4$	$Q(X = 0) = 0.6$

$$H(P, Q_1) = -\sum p_i \log_2 q_i = -0.5 * \log_2 0.2 - 0.5 * \log_2 0.8 = 1.32$$

$$H(P, Q_2) = -\sum p_i \log_2 q_i = -0.5 * \log_2 0.4 - 0.5 * \log_2 0.6 = 1.03$$

$$H(P) = -\sum p_i \log_2 p_i = -0.5 * \log_2 0.5 - 0.5 * \log_2 0.5 = 1$$

KL散度以Kullback和Leibler名字命名，也称**相对熵** (Relative Entropy) 。

□ 作用：衡量两个概率分布之间差异。

□ 公式：
$$\begin{aligned} D_{KL}(P \parallel Q) &= \sum_i p_i (I_i^q - I_i^p) \quad \# I_i^q - I_i^p \text{为信息量之差} \\ &= \sum_i p_i (\log(1/q_i) - \log(1/p_i)) = \sum_i p_i \log(p_i/q_i) \\ &= \sum_i p_i \log(1/q_i) - \sum_i p_i \log(1/p_i) \\ &= H(p, q) - H(p) \end{aligned}$$

□ 性质：

- 1. 由吉布斯公式可知： $D_{KL}(P \parallel Q) \geq 0$ 。
- 2. $D_{KL}(P \parallel Q) \neq D_{KL}(Q \parallel P)$ 。

$D_{KL}(P \parallel Q)$: 以 P 为真实概率分布，预测概率分布 Q 与真实概率分布 P 之间的差距。

$D_{KL}(Q \parallel P)$: 以 Q 为真实概率分布，预测概率分布 P 与真实概率分布 Q 之间的差距。

- 由上可知, KL散度 $D_{KL}(P||Q)$ 表示, **真实分布 P 与预测分布 Q** 之间的度量, 所以
我们可直接将损失函数定义为 KL散度: $Loss = D_{KL}(P||Q)$ 。

- 我们希望 模型的真实分布 P 与预测分布 Q 完全相同, 即:

$$Loss = D_{KL}(P||Q)=0.$$

- 损失函数:

$$Loss = D_{KL}(P||Q) = H(P, Q) - H(P) = \sum_i p_i \log(1/q_i) - \sum_i p_i \log(1/p_i)$$

- 在模型训练中, 样本的真实标签 P 是确定的, 因此 $H(P)$ 是一个常数。通常只取
KL散度的第一项 (即交叉熵) 去度量 P 和 Q 的相似度。对应损失函数称为**交叉熵
损失函数**。

$$Cross_Entropy_Loss = H(P, Q) = -\sum_i p_i \log(q_i)$$

交叉熵损失函数 (Cross Entropy Loss)

- 对互斥的分类问题，通常采用**独热 (OneHot) 编码**，即真实类别概率为1，其他类别概率都为0、长度为 $|Y|$ 的向量表示，例如：

类别	c_1	c_2	c_3	c_4
OneHot编码	0	1	0	0

- 则有： $H(P = y_i) = -\sum_i y_i \log(y_i) = 0$ 。那么，损失函数可进一步化简为：

$$Loss = D_{KL}(P \parallel Q) = H(P, Q) - H(P) = H(P, Q) = -\sum_i y_i \log(f(x_i))$$

- 特别地，二分类对应二元交叉熵损失 (Binary_Cross_Entropy_Loss)：

$$Loss = H(P, Q) = -y \log(f(x)) - (1 - y) \log(1 - f(x))$$