HE00235 《机器学习与模式识别》 2026-2027-1 第 1 次作业

姓名： 学号： 班级：_____

使用说明

本份是**照着誊写**用的手写稿：已知数据、公式、每一步中间数值、最终答案都已排好（题目原文不抄，各小标题已写明要求什么）。黑色宋体正文和表格**必须抄**；灰色楷体的小字是提示，**可以不抄——**篇幅不够时优先省它们。

按 5 页手写 A4（5mm 方格、每页 34×41 格）算过账：必抄正文表格 + 三处手绘图共 185 行，5 页共 205 行，**余量 20 行**；灰色提示另有 30 行，抄不下就省。ROC 曲线（第 1 题 (1)）、梯度下降流程图（第 4 题 (1)）、决策树（第 5 题 (3)）是**要画的**不是要抄的，正文已把顶点、方框、分支写成文字，照着画即可。

表格全部是纵向的（每行 3–6 格），按手写一行行往下抄即可，没有需要横排的大宽表。

全部数值经独立方法复核，逐条记在最后一页「答案汇总与复核记录」里（那一页不用誊写）。

题目—页码对照（按此顺序誊写）

题号	题目	对应页
1	ROC 曲线与性能指标	P2 – P3
2	岭回归与 Lasso 的梯度向量及闭式解	P3 – P4
3	逻辑回归损失函数的梯度证明	P4
4	梯度下降法（流程图 + 迭代 3 次）	P4 – P5
5	信息增益、Gini 指数构造决策树	P5 – P6
—	答案汇总与复核记录（不用誊写）	P7

只有 P2 – P6 需要誊写，正好 5 页 A4；最后一页是自查用的，不必抄。

第 1 题　ROC 曲线与性能指标

题目　用已训练好的学习器对 10 个测试样本（5 正例、5 反例）求 ROC 曲线与各项指标。

已知数据　与　阈值 0.50 的判定结果

样本	真实类别	预测概率	预测类别	是否正确
1	1	0.85	1	√
2	1	0.75	1	√
3	-1	0.15	-1	√
4	-1	0.34	-1	√
5	1	0.46	-1	×
6	1	0.28	-1	×
7	1	0.57	1	√
8	-1	0.46	-1	√
9	-1	0.28	-1	√
10	-1	0.62	1	×

其中正例 $P=5$，负例 $N=5$；后两列是第 (2) 问按阈值 0.50 判定得到的结果。

（1）要求给出该学习器的 ROC 曲线。

步骤 1　阈值从 $+\infty$ 降到 $-\infty$，按预测概率降序逐个「接纳」为正例，累计算 $TPR = TP/P$ 与 $FPR = FP/N$。**同分的样本必须作为一组同时接纳**。

阈值	本步新接纳的样本	累计 TPR	累计 FPR
0.85	{1}	0.20	0.00
0.75	{2}	0.40	0.00
0.62	{10}	0.40	0.20
0.57	{7}	0.60	0.20
0.46	{5, 8}	0.80	0.40
0.34	{4}	0.80	0.60
0.28	{6, 9}	1.00	0.80
0.15	{3}	1.00	1.00

同分不能拆开：若把同分的两个样本拆开先后接纳，梯形法算出的面积会变（0.46 组让样本 8 先得 0.72、0.28 组让样本 6 先得 0.80），只有整组接纳才等于 0.76。

步骤 2　按上表累计的 TPR / FPR 依次连线（横轴 FPR、纵轴 TPR，各 0→1），得 ROC 曲线，共 **9** 个顶点 = 起点 (0, 0) 加上表 8 行的 (FPR, TPR)。

步骤 3　AUC（曲线下面积，梯形法；$\Delta FPR = 0$ 的竖直线段不贡献面积）

$$AUC = 0.20\times0.40 + 0.20\times0.70 + 0.20\times0.80 + 0.20\times0.90 + 0.20\times1.00 = 0.08 + 0.14 + 0.16 + 0.18 + 0.20 = \mathbf{0.76}$$

（2）取阈值 0.50 作为正例的预测，求混淆矩阵与各项指标

步骤 1　判定规则：预测概率 ≥ 0.50 判为正例 $+1$，否则判为负例 -1；逐样本判定结果即上表第 4、5 两列。

步骤 2　由判定结果统计混淆矩阵（以 $+1$ 为正类）。

混淆矩阵	预测为正例 $(+1)$	预测为负例 (-1)
实际为正例 $(+1)$	TP = 3　{1, 2, 7}	FN = 2　{5, 6}
实际为负例 (-1)	FP = 1　{10}	TN = 4　{3, 4, 8, 9}

步骤 3　计算各项指标（原题点名要的五项，中英名别写反）。

指标（原题用名 / 英文）	计算式 = 代入数值	结果
错误率　Error rate	(FP + FN)/10 = (1 + 2)/10	0.30
精度　Accuracy	(TP + TN)/10 = (3 + 4)/10	0.70
查准率　Precision	TP/(TP + FP) = 3/4	0.75
查全率　Recall	TP/(TP + FN) = 3/5	0.60
F1 score	2PR/(P + R) = 2×0.75×0.60/1.35	0.667

第 2 题　岭回归与 Lasso 回归的梯度向量及闭式解

记号　$D = \{(x_i, y_i) \mid i = 1, \ldots, n\}$；设计矩阵 $X \in \mathbb{R}^{n\times d}$（第 i 行为 $x_i^{\top}$），$y = (y_1, \ldots, y_n)^{\top}$，$\theta \in \mathbb{R}^d$，$\lambda > 0$。

（一）岭回归（Ridge Regression，L2 正则化）

目标函数　$\min_\theta J_{ridge}(\theta) = \sum_{i=1}^{n} (y_i - \theta^{\top}x_i)^2 + \lambda \sum_{j=1}^{d} \theta_j^2 = \|y - X\theta\|_2^2 + \lambda\|\theta\|_2^2$

逐分量求导　$\partial J_{ridge}/\partial\theta_j = \sum_{i=1}^{n} 2(y_i - \theta^{\top}x_i)(-x_{ij}) + 2\lambda\theta_j$

梯度向量　$\nabla J_{ridge}(\theta) = -2X^{\top}(y - X\theta) + 2\lambda\theta = 2(X^{\top}X + \lambda I)\theta - 2X^{\top}y$　　（I 为 $d\times d$ 单位矩阵）

令梯度为零　$\nabla J_{ridge}(\theta) = 0 \implies (X^{\top}X + \lambda I)\theta = X^{\top}y$

闭式解　$\boldsymbol{\theta^*_{ridge} = (X^{\top}X + \lambda I)^{-1} X^{\top}y}$

$\lambda > 0$ 保证 $X^{\top}X + \lambda I$ 正定可逆，故唯一解总存在（即使 $X^{\top}X$ 奇异）。

（二）Lasso 回归（L1 正则化）

目标函数　$\min_\theta J_{lasso}(\theta) = (1/2n) \sum_{i=1}^{n} (y_i - \theta^{\top}x_i)^2 + \lambda \sum_{j=1}^{d} |\theta_j| = (1/2n)\|y - X\theta\|_2^2 + \lambda\|\theta\|_1$

$\partial J_{lasso}/\partial\theta_j = (1/n) \sum_{i=1}^{n} (y_i - \theta^{\top}x_i)\, x_{ij} + \lambda \cdot \partial|\theta_j|/\partial\theta_j$

其中　$\partial|\theta_j|/\partial\theta_j = \operatorname{sgn}(\theta_j)$　$(\theta_j \neq 0)$

梯度向量　$\nabla J_{lasso}(\theta) = (1/n)X^{\top}(X\theta - y) + \lambda \operatorname{sgn}(\theta)$

闭式解　**不存在**。$\|\theta\|_1$ 在 $\theta_j = 0$ 处不可导，而最优解恰好大量落在坐标轴上，无法像岭回归那样令梯度为零直接解出 θ；即使 X 列满秩使 $X^{\top}X$ 可逆也一样。

求解办法　坐标下降 + 软阈值迭代：固定其余坐标，记　$a = (1/n)\|x_j\|^2$，　$g = (1/n)\, x_j^{T}(y - X_{-j}\theta_{-j})$　（残差 e_{-j} 已排除第 j 列），则　$\theta_j = S_{\lambda/a}(g/a) = (1/a)\cdot \mathrm{sign}(g)\cdot \max(|g| - \lambda, 0)$

第 3 题　证明逻辑回归损失函数的梯度

$J(\theta) = -(1/m)\,\Sigma_{i=1}^{m}\,[\, y^{(i)} \log(p^{(i)}) + (1 - y^{(i)}) \log(1 - p^{(i)})\,]$，证明其对 θ_j 的偏导数。

证明第一步　求 $\mathbf{p^{(i)}}$ 对 $\boldsymbol{\theta_j}$ 的导数

记 $p^{(i)} = \sigma(\theta^{T}x^{(i)})$，$\sigma(z) = 1/(1 + e^{-z})$，$x^{(i)} \in R^{d}$，$y^{(i)} \in \{0, 1\}$。由 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ 及 $\partial(\theta^{T}x^{(i)})/\partial\theta_j = x_j^{(i)}$（因 $\theta^{T}x = \Sigma_i\ \theta_i x_i$），得

$\partial p^{(i)}/\partial\theta_j = \sigma'(\theta^{T}x^{(i)}) \cdot \partial(\theta^{T}x^{(i)})/\partial\theta_j = p^{(i)}(1 - p^{(i)}) \cdot x_j^{(i)}$

证明第二步　代入损失函数求导，通分后合并同类项

$\partial J/\partial\theta_j = -(1/m)\,\Sigma_{i=1}^{m}\,[\, y^{(i)} \cdot (1/p^{(i)}) \cdot \partial p^{(i)}/\partial\theta_j \;-\; (1 - y^{(i)}) \cdot (1/(1 - p^{(i)})) \cdot \partial p^{(i)}/\partial\theta_j\,]$

$= -(1/m)\,\Sigma_{i=1}^{m}\,[\, y^{(i)}(1 - p^{(i)}) - (1 - y^{(i)})p^{(i)}\,] \,/\, [\, p^{(i)}(1 - p^{(i)})\,] \cdot p^{(i)}(1 - p^{(i)}) \cdot x_j^{(i)}$

$= -(1/m)\,\Sigma_{i=1}^{m}\,[\, y^{(i)} - y^{(i)}p^{(i)} - p^{(i)} + y^{(i)}p^{(i)}\,] \cdot x_j^{(i)} \;=\; (1/m)\,\Sigma_{i=1}^{m}\,(\, p(\theta^{T}\cdot x^{(i)}) - y^{(i)}\,)\, x_j^{(i)}$　　■

第 4 题　梯度下降法求解

题目　用梯度下降法解 $J(\theta) = \theta_1^{2} + \theta_2^{2} + 3$，初值 $\theta^{(0)} = (1, 2)$、$\eta = 0.1$，求迭代 3 次后的 θ。

（1）梯度下降法求解的基本流程图

流程（照下面自己画，灰色可不抄）：　**开始**　→ **初始化**（选定初值 $\theta^{(0)}$、步长 η、精度 ε、最大迭代次数 k）　→ **计算梯度** $\nabla J(\theta^{(k)})$ → **判断** $\|\nabla J(\theta^{(k)})\| < \varepsilon$?

「是」→ **输出解** $\theta^{(k)}$（本题迭代 3 次，故取 k = 3）；「否」→ **更新** $\theta^{(k+1)} = \theta^{(k)} - \eta\nabla J(\theta^{(k)})$，置 k = k+1，返回「计算梯度」框（「否」那一支有一条回边）。

（2）迭代 3 次的计算过程

步骤 1 求梯度并写出迭代公式

$J(\theta) = \theta_1^{2} + \theta_2^{2} + 3 \;\Longrightarrow\; \partial J/\partial\theta_1 = 2\theta_1$，$\partial J/\partial\theta_2 = 2\theta_2$，即 $\nabla J(\theta) = (\, 2\theta_1, 2\theta_2\,)^{T}$

迭代公式 $\theta^{(k+1)} = \theta^{(k)} - \eta\,\nabla J(\theta^{(k)})$，即逐分量 $\theta_j^{(k+1)} = (\, 1 - 2\eta\,)\,\theta_j^{(k)}$

步骤 2 逐次迭代计算

初始目标值：　$J(\theta^{(0)}) = 1^{2} + 2^{2} + 3 = 8$

第 1 次 $\nabla J(\theta^{(0)}) = (\, 2\times1, 2\times2\,)^{T} = (\, 2, 4\,)^{T}$，　$\theta^{(1)} = (\, 1 - 0.1\times2,\ 2 - 0.1\times4\,) = (\,\mathbf{0.8}\,,\,\mathbf{1.6}\,)$

$J(\theta^{(1)}) = 0.8^{2} + 1.6^{2} + 3 = 0.64 + 2.56 + 3 = \mathbf{6.2}$

第 2 次 $\nabla J(\theta^{(1)}) = (\, 1.6, 3.2\,)^{T}$，　$\theta^{(2)} = (\, 0.8 - 0.1\times1.6,\ 1.6 - 0.1\times3.2\,) = (\,\mathbf{0.64}\,,\,\mathbf{1.28}\,)$

$J(\theta^{(2)}) = 0.64^{2} + 1.28^{2} + 3 = 0.4096 + 1.6384 + 3 = \mathbf{5.048}$

第 3 次 $\nabla J(\theta^{(2)}) = (\, 1.28, 2.56\,)^{T}$，　$\theta^{(3)} = (\, 0.64 - 0.1\times1.28,\ 1.28 - 0.1\times2.56\,) = (\,\mathbf{0.512}\,,\,\mathbf{1.024}\,)$

$J(\theta^{(3)}) = 0.512^2 + 1.024^2 + 3 = 0.262144 + 1.048576 + 3 = \mathbf{4.31072}$

迭代 3 次后：　$\theta = \theta^{(3)} = (0.512, 1.024)$，　$J = 4.31072$

J 依次为 $8 \to 6.2 \to 5.048 \to 4.31072$，单调下降；通项 $\theta^{(k)} = 0.8^k\theta^{(0)}$ 给出极小点 $\theta^* = (0, 0)$、$J = 3$。

第 5 题　分别用信息增益、Gini 指数构造决策树

数据表见原题（15 个样本 ×4 个条件属性，类别「是」9 个、「否」6 个）。为便于复核，各属性的分支构成直接列在下面步骤 2 的表里：

（1）信息增益　　（2）Gini 指数（两准则逐步比较，最终得到同一棵树）

步骤 1　根结点的信息熵与 Gini 指数

$H(D) = -(9/15)\log_2(9/15) - (6/15)\log_2(6/15) = -0.6\times(-0.7370) - 0.4\times(-1.3219) = \mathbf{0.9710}$

$Gini(D) = 1 - (9/15)^2 - (6/15)^2 = 1 - 0.36 - 0.16 = \mathbf{0.4800}$

步骤 2　各属性的分支构成、条件熵 / 加权 Gini 与两种增益

属性	分支构成 n:是/否	条件熵 H	信息增益	加权 Gini	Gini 增益
年龄	青年 5:2/3；中年 5:3/2；老年 5:4/1	0.8879	0.0830	0.4267	0.0533
有工作	否 10:4/6；是 5:5/0	0.6473	**0.3237**	0.3200	**0.1600**
有自己的房子	否 8:3/5；是 7:6/1	0.7851	0.1858	0.3643	0.1157
信贷情况	一般 5:1/4；好 6:4/2；非常好 4:4/0	0.6080	**0.3630**	0.2844	**0.1956**

表中 5:1/4 表示「样本数 : 是 : 否」。以两准则都最大的「信贷情况」为例：

$H(\text{信贷}) = (5/15)\times0.7219 + (6/15)\times0.9183 + (4/15)\times0 = 0.2406 + 0.3673 + 0 = 0.6080$，　$Gain = H(D) - H(\text{信贷}) = 0.9710 - 0.6080 = \mathbf{0.3630}$（信息增益最大）

$Gini(\text{信贷}) = (5/15)\times0.3200 + (6/15)\times0.4444 + (4/15)\times0 = 0.1067 + 0.1778 + 0 = 0.2844$，　$Gain = 0.4800 - 0.2844 = \mathbf{0.1956}$（Gini 增益最大）

步骤 3　递归划分

两准则的根结点都按 **信贷情况** 划分（增益 0.3630 与 0.1956 均为最大）；子结点及各叶的样本集、判定见图 5-1。

注：「信贷 = 一般」结点上「有工作」与「有自己的房子」增益并列最大，但二者划出的子集完全相同（是：{4}；否：{1,5,6,15}），取靠前的「有工作」即可，不影响结果。

（3）两种准则得到的决策树

两种准则在每个结点选出的最优划分属性完全一致，最终得到**同一棵树**。**照下面的结构自己画成方框图**（方框 = 结点、方框之间的连线 = 分支），画的时候把属性名、样本集、增益值都标在框上。读法：内部结点括号内为「是数 / 否数」，叶结点为「判是的个数 / 该叶样本总数」，例如 (3/3) 表示该叶 3 个样本全判「是」。



图 5-1 决策树结构（下方缩进仅为参考，实际画成方框图）

共 **7 个叶结点**（4 判「是」、3 判「否」），15 个训练样本全部判对，训练误差为 0。

答案汇总与复核记录（誊写完成后自查用，不用誊写）

题号	小问	内容	结果
1	(1)	ROC 曲线顶点 / AUC	顶点共 9 个 = 起点 (0,0) + 阈值表 8 行的 (FPR, TPR)；**AUC = 0.76**
1	(2)	混淆矩阵（以 +1 为正类）	TP = 3，FP = 1，FN = 2，TN = 4
1	(2)	错误率 / 精度	(FP+FN)/10 = **0.30** / (TP+TN)/10 = **0.70**
1	(2)	查准 / 查全 / F1	Precision = **0.75**，Recall = **0.60**，F1 = **0.667**
2	(一)	岭回归梯度与闭式解	$\nabla J = -2X^T(y-X\theta)+2\lambda\theta = 2[(X^TX+\lambda I)\theta - X^Ty]$； $\theta^* = \mathbf{(X^TX+\lambda I)^{-1}X^Ty}$
2	(二)	Lasso 梯度与闭式解	$\nabla J = (1/n)X^T(X\theta-y) + \lambda\cdot\mathrm{sgn}(\theta)$； 闭式解**不存在**，用坐标下降 + 软阈值
3	—	逻辑回归损失梯度	$\partial J/\partial\theta_j = \mathbf{(1/m)\Sigma(p(\theta^T\cdot x^{(i)}) - y^{(i)})x_j^{(i)}}$
4	(1)	梯度下降基本流程图	按步骤 (1) 给出的 6 个框 + 1 条回边自己画
4	(2)	迭代 3 次后 θ 与 J	$\theta^{(3)}$ = **(0.512, 1.024)**； J：8 → 6.2 → 5.048 → **4.31072**
5	(1)(2)	两准则的根结点划分	H(D) = 0.9710 → 信贷情况（增益 **0.3630**）； Gini(D) = 0.4800 → 信贷情况（增益 **0.1956**）
5	(3)	两准则的结果	得到**完全相同**的决策树，见图 5-1；7 个叶结点，训练样本全判对

复核记录

题号	正文给出的数	用什么方法复核	复核结果
1	AUC = 0.76	梯形法 vs Mann-Whitney U 统计量（并列得分各计 0.5：18 严格胜出 + 2 并列各半分 = 19，19/25）	两法一致
1	同分必须整组接纳	把 0.46、0.28 两组分别按相反次序拆开重算梯形面积	拆开后得 0.80 / 0.76 / 0.76 / 0.72，只有整组接纳唯一等于 0.76
2	梯度与闭式解	逐分量梯度与矩阵形式对照；软阈值式由目标函数独立推一遍	一致
3	$\partial J/\partial\theta_j$ 的解析式	随机取样本做中心差分数值求导，与解析梯度逐分量比对	差异小于 10^{-9}
4	$\theta^{(3)}$ = (0.512, 1.024)	与通项 $\theta^{(k)} = (1-2\eta)^k\theta^{(0)} = 0.8^k\theta^{(0)}$ 比对	k = 0,1,2,3 全部吻合
5	H(D) / Gini(D) 与两种增益	从 15 行原始数据独立重算两准则的分支计数、条件熵与加权 Gini	与表内数值逐格一致；两准则独立递归建树后结构相同

文档本身另过了四道自动门禁：未解析标记残留扫描、表格宽度与列数核对、上下标记账与 XML 中 vertAlign 数量对账、DOCX 与 PDF 全文一致性；并对其中两道关键门禁做了变异测试（注入已知错误，确认门禁抓得住），第 1 题 7/7、第 5 题 6/6 全中。誊写用量也实测过：必抄 + 手绘共 185 行，5 页手写 A4 共 205 行。