




# 自然语言处理

## 第一章：绪论

授课老师： 缪尧



注意：本PPT仅供个人学习使用，任何组织和个人不得公开传播或用于任何商业盈利用途，否则一切后果由该组织或个人承担。

部分材料引用来源：王东、马少平《图解人工智能》，百度飞桨课程



# 课程安排

# 课程安排

## 课程内容与学时安排 (36+18)

| 章节 | 内容                             | 课时 |
|----|--------------------------------|----|
| 1  | 绪论                             | 2  |
| 2  | 机器学习算法与神经网络基础 (RNN, LSTM等)     | 2  |
| 3  | 中文分词和关键词提取                     | 4  |
| 4  | 词向量技术 (Word2Vec, Transformer等) | 4  |
| 5  | 文本分类与文本信息抽取                    | 4  |
| 6  | 机器阅读理解与文本摘要                    | 4  |
| 7  | 对话系统、语音处理                      | 4  |
| 8  | 预训练大模型 (ChatGPT等)              | 4  |
| 9  | 智能医学NLP (智能医学文本挖掘、辅助诊疗对话等)     | 4  |
|    | 团队作业展示、习题课、复习、答疑               | 4  |

| 章节   | 内容       | 课时 |
|------|----------|----|
| 验证实验 | 自然语言处理基础 | 2  |
| 设计实验 | 设计实验1    | 4  |
|      | 设计实验2    | 4  |
|      | 设计实验3    | 4  |
|      | 课程设计     | 4  |



上机实验18学时

理论授课36学时  
(理论基础+实例分析)



# 课程安排

## 参考教材（包括但不限于）：



## 参考资料：

国内外公开课资源（MIT NLP、MOOC、网易公开课、飞桨AI studio等）、期刊论文、会议论文等。



# 课程安排

## ● 平时成绩50%

考勤+课堂互动10%

团队作业5%=1次\*5%/次

随堂测验10%=1次\*10%/次 (没有补测)

实验成绩15%=3次\*5%/次

课程设计10%=1次\*10%/次

## ● 期末考试50% (闭卷)

注意:

(1) 缺勤次数 $\geq 1/3$ 将取消期末考试资格;

(2) 请假: 需要假条



01

**NLP的基本概念**

02

**NLP的技术与应用**

03

**NLP的发展历程**

04

**NLP的主要难点**

[https://www.bilibili.com/video/BV1Jt421V7YT/?spm\\_id\\_from=333.788.recommend\\_more\\_video.1&vd\\_source=852986d37ebf7f3667eb666215641be3](https://www.bilibili.com/video/BV1Jt421V7YT/?spm_id_from=333.788.recommend_more_video.1&vd_source=852986d37ebf7f3667eb666215641be3)




# Part 01


## NLP的基本概念

# NLP的基本概念

语言是人类所特有的用来表达意思、交流思想的工具。



# NLP的基本概念




您好



喵喵



01011




01

语言出现的目的是为了人与人之间的**通信**。



自然语言是随着人类社会发展演变而来的语言，是人类学习生活的重要工具。






02

自然语言的本质就是**信息**的**载体**。




人类的绝大部分知识是以语言文字的形式记载和流传下来的。

# NLP的基本概念




# ■ NLP的基本概念



人们处在不同的国家，使用不同的语言，通过不同的手段和方式发表不同的言论（微博/微信/Meta、公众号、小红书、专著、论文、网页等），千丝万缕的关系将他/她们联系在一起，构成一个特定的社会网络。如何发现或挖掘不同的任务、事件和地点之间的关联？如何为每个人提供最便捷、最简单的个性化信息服务？


图片来源: [https://cn.bing.com/images/search?view=detailV2&ccid=gALpmpmM&id=84D8DF75F08756DAF9D786BC5B83BEF85F8795D2&thid=OIP.gALpmpmMVcrxfBykB6LXDAHaD4&mediaurl=https%3a%2f%2fts1.cn.mm.bing.net%2fth%2fid%2fr-C.8002e999ea4c55caf17c1ca407a2d70c%3frik%3d0pWHX%252fi%252b1u8hg%26riu%3dhttp%253a%252fi%252fimg95.699pic.com%252fphoto%252f40133%252f5351.gif\\_wh860.gif%26ehk%3dAzC5MarZ1bmaTjGpP5F8KQRN%252bE7IL70SWuMcLAcbuJ%253d%26risl%3d%26pid%3dImgRaw%26r%3d0&expH=450&expW=860&q=%e7%8e%af%e7%90%83%e6%97%85%e6%b8%b8+gif&simid=608002133783413786&FORM=IRPRST&ck=85EBF8CCE2B9B1CC3903F468FE214A98&selectedIndex=0&itb=0&idpp=overlayview&ajaxhist=0&ajaxserp=0](https://cn.bing.com/images/search?view=detailV2&ccid=gALpmpmM&id=84D8DF75F08756DAF9D786BC5B83BEF85F8795D2&thid=OIP.gALpmpmMVcrxfBykB6LXDAHaD4&mediaurl=https%3a%2f%2fts1.cn.mm.bing.net%2fth%2fid%2fr-C.8002e999ea4c55caf17c1ca407a2d70c%3frik%3d0pWHX%252fi%252b1u8hg%26riu%3dhttp%253a%252fi%252fimg95.699pic.com%252fphoto%252f40133%252f5351.gif_wh860.gif%26ehk%3dAzC5MarZ1bmaTjGpP5F8KQRN%252bE7IL70SWuMcLAcbuJ%253d%26risl%3d%26pid%3dImgRaw%26r%3d0&expH=450&expW=860&q=%e7%8e%af%e7%90%83%e6%97%85%e6%b8%b8+gif&simid=608002133783413786&FORM=IRPRST&ck=85EBF8CCE2B9B1CC3903F468FE214A98&selectedIndex=0&itb=0&idpp=overlayview&ajaxhist=0&ajaxserp=0)

# NLP的基本概念



# NLP的基本概念

人物、事件关系分析意义重大



# NLP的基本概念

## 使计算机具备处理人类语言的能力

如何让计算机来分析语言文本，理解人的意图，根据不同用户的需求实现个性化信息服务？这项技术就是NLP。



图片来源:

[https://cn.bing.com/images/search?view=detailV2&ccid=4ybyWavi&id=B33C7C0F5793EED80988D8629B9511E43BEEB3B9&thid=OIP.4ybyWavijO\\_vkZManb2O9gHaHa&mediaurl=https%3a%2f%2fwimg.588ku.com%2fgif%2f21%2f05%2f21%2f51bb978449b3f1182f0e0c6d082f6010.gif&expw=800&expw=800&q=%e8%b7%a8%e6%96%87%e5%8c%96%e4%ba%a4%e6%b5%81&gif&simid=608032185700131816&FORM=IRPRST&ck=DCA0D215F4AD7273E5709DE7D1EDBCA3&selectedIndex=0&itb=0&idp=overlayview&ajaxhist=0&ajaxserp=0](https://cn.bing.com/images/search?view=detailV2&ccid=4ybyWavi&id=B33C7C0F5793EED80988D8629B9511E43BEEB3B9&thid=OIP.4ybyWavijO_vkZManb2O9gHaHa&mediaurl=https%3a%2f%2fwimg.588ku.com%2fgif%2f21%2f05%2f21%2f51bb978449b3f1182f0e0c6d082f6010.gif&expw=800&expw=800&q=%e8%b7%a8%e6%96%87%e5%8c%96%e4%ba%a4%e6%b5%81&gif&simid=608032185700131816&FORM=IRPRST&ck=DCA0D215F4AD7273E5709DE7D1EDBCA3&selectedIndex=0&itb=0&idp=overlayview&ajaxhist=0&ajaxserp=0)

# NLP的基本概念

自然语言处理（Natural language processing, NLP）是研究如何利用计算机技术对语言文本（句子、篇章或话语等）进行处理和加工的一门学科，研究内容包括对词法、句法、语义和语用等信息的识别、分类、提取、转换和生成等各种处理方法和实现技术。

--《计算机百科全书》，清华大学出版社，2018.5

人工智能皇冠上的明珠



# NLP的基本概念

研究内容

语音技术

语音

语音识别

语音合成

说话人识别

...

文字

分析处理

文本分类

情感分类

观点挖掘

主题发现

信息检索

文字校对

...

自然语言处理

OCR

图像/视频识别

计算机视觉

理解生成

机器翻译

自动摘要

问答系统

自动写作

...

多模态信息处理

语音摘要

人机对话


语音翻译

文档分析

图像/视频翻译

多模态人机交互

# 语音识别



## 语音识别技术

语音识别是将人类语音转换为文本的过程，通过声学信号处理和自然语言理解技术实现。

## 应用场景

医生可以通过语音识别软件快速记录病人病例、会议记录与字幕生成等。

## 技术挑战

口音和方言的多样性、背景噪声和回声干扰、同音词和歧义性、实时性和计算资源限制等。

# 语音合成



## 语音合成技术

将文本转换为语音的技术，涉及声学、语言学、数字信号处理等多个领域。

## 应用场景

智能语音助手、无障碍阅读系统、自动电话应答系统等。

## 技术挑战

提高语音合成的自然度、流畅度和可懂度，以及适应不同说话风格和语音环境。

# 说话人识别

[https://www.bilibili.com/video/BV1Hb41187e1/?spm\\_id\\_from=333.788.recommend\\_more\\_video.0&vd\\_source=852986d37ebf7f3667eb666215641be3](https://www.bilibili.com/video/BV1Hb41187e1/?spm_id_from=333.788.recommend_more_video.0&vd_source=852986d37ebf7f3667eb666215641be3)

01

## 说话人识别技术

通过语音信号识别说话人身份的技术，包括声纹识别和语音识别两个方面。

02

## 应用场景

安全认证、语音门禁、智能客服等。

03

## 技术挑战


提高识别准确率、降低误识率，以及处理噪声和变声等复杂情况。



# 说话人识别----声纹识别的应用

目前，声纹识别技术已经有一些商业应用，但总体来说性能还有待加强，特别是复杂环境下（如远场、噪音、跨领域）的识别效果距离实用还有较大差距。

右图是在银行场景下进行认证的例子。用户输入8个数字进行声纹注册；注册之后即可用声音进行身份认证。



# 文本分类

## 文本分类技术

将文本按照一定规则或标准划分为不同类别的技术，如新闻分类、垃圾邮件识别等。

## 应用场景

内容推荐、舆情监测、产品评价分析等。



## 技术挑战

提高分类准确性、处理文本中的歧义和隐含意义，以及适应不同领域和语言的文本特点。

# 观点挖掘与主题发现

## 观点挖掘

通过分析文本内容，挖掘出人们对某一事物或事件的观点、态度和情感倾向。




## 主题发现

利用文本聚类、**LDA**等模型，从大量文本数据中自动发现潜在的主题和话题。

## 应用场景

产品评价分析、社交媒体舆情监测、新闻报道主题追踪等。

# 文字校对



## 文字校对

利用自然语言处理技术，对文本进行错别字检查、语法错误纠正等，提高文本质量和可读性。



## 应用场景

搜索引擎、文档管理系统、出版物校对等。

# 自动文摘

## ● 自动文摘


通过自动提取文本中的关键信息，生成简洁明了的摘要，帮助用户快速了解文本主要内容。

## ● 应用场景

新闻报道、科技论文等。



# 问答系统与自动写作技术



## 问答系统

基于自然语言处理技术的自动问答系统能够理解用户的问题，并从知识库中获取相关信息，最终回答用户的问题。这种技术可以应用于智能客服、智能助手等场景，提高用户获取信息和解决问题的效率。

## 自动写作技术

利用自然语言处理技术，计算机可以自动生成文章、新闻、摘要等文本内容。这种技术可以大大提高文本生成的效率和质量，为新闻媒体、广告营销等领域提供便利。

### 孙悟空大战李逵

孙悟空是鼎鼎有名的斗战胜佛，李逵则是地煞星出身，二人本身就有宿怨。

一日，天界与人间的界限之处，云雾缭绕，风云突变。孙悟空与李逵在一座荒芜的古战场上偶然相遇，这座战场见证了无数古代英雄的较量，今日又将上演一场史诗对决。

孙悟空，以他的如意金箍棒一挥，声势浩大，天空中雷声大作。他的眼中闪烁着战斗的兴奋，因为他知道李逵的力大无穷，绝非等闲之辈。而李逵，手持双斧，身体魁梧，眼神中透露着野性的光芒，他对孙悟空的出现既惊讶又兴奋，这正是他期待的挑战。

“斗战胜佛，今日我李逵要看看你的金箍棒厉害，还是我双斧更胜一筹！”李逵大吼一声，挥斧直冲孙悟空。孙悟空不屑一笑，身形一晃，瞬间化作三头六臂，每一只手都握着金箍棒，挥舞形成一道道金光，抵挡李逵的斧风。二人在战场上你来我往，斗得天昏地暗，山河颤动。战斗持续了半晌，孙悟空凭借轻灵的身法和深厚的法力渐渐占据上风。李逵虽力大如牛，但在孙悟空变化多端的攻势下，逐渐感到力不从心。突然，孙悟空化作一道金光，直击李逵，李逵猝不及防，被击中胸口，倒飞出去，重重地摔在地上 .....

# OCR与图像/视频识别技术

## OCR技术


OCR (Optical Character Recognition, 光学字符识别) 技术可以将图像中的文字转换成可编辑的文本格式, 便于后续处理和分析。这种技术在文档数字化、车牌识别等领域有广泛应用。

科大讯飞:

[https://www.bilibili.com/video/BV1By4y1q7NJ/?spm\\_id\\_from=333.337.search-card.all.click&vd\\_source=852986d37ebf7f3667eb666215641be3](https://www.bilibili.com/video/BV1By4y1q7NJ/?spm_id_from=333.337.search-card.all.click&vd_source=852986d37ebf7f3667eb666215641be3)

## 图像/视频识别技术

通过自然语言处理与计算机视觉技术的结合, 可以实现图像和视频中的文字、物体、场景等信息的自动识别和理解。这种技术在智能安防、自动驾驶等领域具有重要应用价值。



# 多模态人机交互技术

google Glass:

[https://www.bilibili.com/video/BV1tW411j762/?spm\\_id\\_from=333.788.recommend\\_more\\_video.0&vd\\_source=852986d37ebf7f3667eb666215641be3](https://www.bilibili.com/video/BV1tW411j762/?spm_id_from=333.788.recommend_more_video.0&vd_source=852986d37ebf7f3667eb666215641be3)

## 多模态交互

结合语音、手势、面部表情等多种交互方式，实现更自然、更智能的人机交互体验。这种技术可以应用于智能家居、智能车载系统等领域。

## 结合情感分析

通过分析用户的语音、文本等信息，识别用户的情感状态和需求，从而提供更贴心的服务和响应。这种技术在客户服务、市场调研等领域有重要应用。



BayMax:


[https://www.bilibili.com/video/BV1R94y197Ui?p=1&vd\\_source=852986d37ebf7f3667eb666215641be3](https://www.bilibili.com/video/BV1R94y197Ui?p=1&vd_source=852986d37ebf7f3667eb666215641be3)



# Part 02

## NLP的技术与应用

# NLP的技术与应用



## 自然语言理解



使计算机理解人类语言表达的意思，即“听懂”。

## 自然语言生成



通过算法生成人类能够理解的内容，即“表达”。

# NLP的技术与应用

自然语言理解和分析是一个层次化过程，从**词法分析**、**句法分析**、**语义分析**到**语用语境分析**，层层递进。

- ❖ 词法分析：分析词汇的各个词素，从中获得语言学信息；
- ❖ 句法分析：分析句子和短语的结构，识别各词语、短语在句中的作用以及相互间的关系；
- ❖ 语义分析：找出词义、结构意义及词与结构结合的意义，确定语言所表达的真正含义；
- ❖ 语用语境分析：分析语言所存在的外界环境对语言使用者所产生的影响。

# NLP的技术与应用

## ❖ 词法分析

词法分析的主要任务是**词性标注**。词性是词汇的基本属性，词性标注是在给定句子中判断并标注各词的词性，其中标注复杂词汇如**兼类词**与**未登录词**的词性是词法分析的重要任务。

（兼类词指的是那些在不同上下文或语境中可以充当不同词类（如名词、动词、形容词等）使用的词语。如“跑”：


作为动词使用：他每天早上都去**跑步**。

作为名词使用：这次**跑步**比赛他赢了。）

| 分词词性            |           |                    |          |                    |          |            |          |           |           |              |
|-----------------|-----------|--------------------|----------|--------------------|----------|------------|----------|-----------|-----------|--------------|
| 谢尔盖·科罗廖夫<br>PER | (<br>w    | 1907年1月12日<br>TIME | -<br>w   | 1966年1月14日<br>TIME | )<br>w   | ,<br>w     | 原<br>a   | 苏联<br>LOC | 宇航<br>n   |              |
| 事业<br>n         | 的<br>u    | 伟大<br>a            | 设计师<br>n | 与<br>c             | 组织者<br>n | ,<br>w     | 第一枚<br>m | 射程<br>n   | 超过<br>v   | 8000公里<br>m  |
| 的<br>u          | 洲际<br>a   | 火箭<br>n            | (<br>w   | 弹道导弹<br>nZ         | )<br>w   | 的<br>u     | 设计者<br>n | ,<br>w    | 第一颗<br>m  | 人造地球卫星<br>nZ |
| 的<br>u          | 运载火箭<br>n | 的<br>u             | 设计者<br>n | ,<br>w             | 第一艘<br>m | 载人航天<br>vm | 飞船<br>n  | 的<br>u    | 总设计师<br>n | .<br>w       |

## ❖ 句法分析

句法分析的主要任务是确定句子的语法结构或句子中词汇间的依存关系，包括确定语言的语法体系，明确符合语法规则的句子的语法结构，以及通过分析语言单位内成分间的依存关系，推导句子的句法结构。



# NLP的技术与应用

## ❖ 语义分析

通过建立有效的模型使计算机能对各个语言单位（包括词汇、句子和篇章等）进行自动语义分析，从而理解自然语言文本的真实语义。根据理解对象的语言单位不同，可将语义分析分为词汇级语义分析、句子级语义分析以及篇章级语义分析。

### 相似词查询

查询

未雨绸缪

基本释义

[ wèi yǔ chóu móu ]

趁着天没下雨，先修缮房屋门窗。比喻事先做好准备。[近义词] 有备无患 | 防微杜渐。[反义词] 亡羊补牢 | 临渴掘井。

未雨绸缪是什么意思 - 汉语词典

未雨绸缪的近义词

居安思危 积谷防饥 防患于未然 早为之所 有备无患

词汇—近义词查询

1. 微信支付与支付宝支付哪个更优？
2. 微信和支付宝，哪个更值得使用？
3. 微信与支付宝，哪个好用呢？
4. 微信和支付宝，究竟哪个更佳？
5. 微信与支付宝哪个更出色？

句子—相似句子生成

### Seizure onset zone identification using phase-amplitude coupling and multiple machine learning approaches for interictal electrocorticogram

Yao Miao<sup>1</sup> · Yasushi Iimura<sup>2</sup> · Hidenori Sugano<sup>2</sup> · Kosuke Fukumori<sup>1</sup> · Toshihisa Tanaka<sup>1,2,3,4</sup>

Received: 13 July 2022 / Revised: 26 October 2022 / Accepted: 17 November 2022 / Published online: 7 December 2022  
© The Author(s) 2022

#### Abstract

Automatic seizure onset zone (SOZ) localization using interictal electrocorticogram (ECoG) improves the diagnosis and treatment of patients with medically refractory epilepsy. This study aimed to investigate the characteristics of phase-amplitude coupling (PAC) extracted from interictal ECoG and the feasibility of PAC serving as a promising biomarker for SOZ identification. We employed the mean vector length modulation index approach on the 20-s ECoG window to calculate PAC features between low-frequency rhythms (0.5–24 Hz) and high frequency oscillations (HFOs) (80–560 Hz). We used statistical measures to test the significant difference in PAC between the SOZ and non-seizure onset zone (NSOZ). To overcome the drawback of handcraft feature engineering, we established novel machine learning models to learn automatically the characteristics of the obtained PAC features and classify them to identify the SOZ. Besides, to handle imbalanced dataset classification, we introduced novel feature-wise/class-wise re-weighting strategies in conjunction with classifiers. In addition, we proposed a time-series nest cross-validation to provide more accurate and unbiased evaluations for this model. Seven patients with focal cortical dysplasia were included in this study. The experiment results not only showed that a significant coupling at band pairs of slow waves and HFOs exists in the SOZ when compared with the NSOZ, but also indicated the effectiveness of the PAC features and the proposed models in achieving better classification performance.

**Keywords** Phase-amplitude coupling (PAC) · Electrocorticogram (ECoG) · Interictal · Focal cortical dysplasia (FCD) · Machine learning

篇章—论文摘要生成

## ❖ 语用语境分析

语用指人对语言的具体运用，自然语言用语与语境、语言使用者的知识涵养、言语行为、想法和表达意图密切相关。语用分析是计算机在情景语境和文化语境中研究分析语言使用者的表达用意。



Hi, 您今天钓到鱼了吗?

运气好极了, 一条都没有钓到



# NLP的技术与应用



## NLP的四个典型应用

01

情感分析




02

信息检索



03

聊天  
机器人



04

机器翻译



# NLP的技术与应用

## 01

### 情感分析

情感分析（意见挖掘），是计算机系统自主对文本的情感倾向（如主观/客观，积极/消极，喜欢/讨厌等）进行挖掘和分析的过程。

喜欢这种好看的狗狗



积极



消极



这真是惊艳世界的“黑科技”



这车耗油，完全难以忍受



火锅真好吃



- 帮助企业分析用户消费习惯
- 分析热点话题和危机舆情监控
- 为企业提供有力的决策支持

# NLP的技术与应用

## 02

### 信息检索

信息检索指信息按照一定的方式组织起来，并根据用户的需要找出有关信息的过程和技术。搜索引擎是当前主流的信息检索方式，如：

Google、必应、百度、搜狗、雅虎等




Google 搜索

手气不错

Google 提供: English



图片来源: <https://www.baidu.com/>  
<https://www.google.com/>  
<https://www.yahoo.co.jp/>  
<https://www.bing.com/>  
<https://www.sogou.com/>



ホームページに設定する

Yahoo! BB | きっず版 | アプリ版 | ヘルプ

LYP  
プレミアム

オークション

ショッピング

YAHOO!  
JAPAN

トラベル

カード

メール

ウェブ 画像 動画 知恵袋 地図 リアルタイム 一覧▼

検索

# NLP的技术与应用

## 03

### 聊天机器人

聊天机器人是自动问答系统的具体应用，设计自然语言的词法、句法、语义等分析问题，是自然语言理解与生成技术应用的集中体现。

- 电商行业中广泛应用的自动回复客服；
- 未来随着智能家居、智能汽车的发展，聊天机器人会有更大的使用价值。




[https://www.bilibili.com/video/BV1gh4y1q7ux/?spm\\_id\\_from=333.337.search-card.all.click&vd\\_source=852986d37ebf7f3667eb666215641be3](https://www.bilibili.com/video/BV1gh4y1q7ux/?spm_id_from=333.337.search-card.all.click&vd_source=852986d37ebf7f3667eb666215641be3)

# NLP的技术与应用

## 04 机器翻译

通过把输入的源语言文本通过自动翻译获得另一种语言的文本，是NLP中最为人熟知的场景，比如Google Translate、百度翻译、DeepL Translate。



# NLP的技术与应用

随着NLP技术研究的不断深入，NLP应用逐步得到推广，尤其在知识图谱、机器翻译、阅读理解和智能创作等方面开始产生较成熟的应用。同时由于大模型时代到来，NLP领域将会取得更多研究成果和发展。





Part 03

# NLP的发展历程

# NLP的发展历程


## 飞跃 21世纪以来

从2008年到现在，在图像识别和语言识别领域的成果激励下，人们也逐渐开始引入**深度学习**来做NLP研究，并在机器翻译、问答系统、阅读理解等领域取得了一定成功。




## 探索

20世纪70年代以前，人们对计算机处理自然语言的认知都局限在用电脑**模拟人脑**的方式，这种方法后来被成为“鸟飞派”。



## 重生 20世纪80-90年代

IBM华生实验室采用基于统计的方法将语音识别率从70%提升到90%。在这一阶段，NLP基于数学模型和**统计**的方法取得了实质性的突破，从实验室走向实际应用。



## 缘起 20世纪50-70年代

1950年，图灵提出了著名的“图灵测试”，这一般被认为是NLP思想的开端。这个时期的NLP停留在理性主义思潮阶段，以基于**规则**的方法为代表。


图片来源: <http://www.moocxing.com/industryangle/34d35369-2cb6-6b8b-c889-98b275544ea2.shtml>

# NLP的发展历程

## NLP领域发展现状如何?

各种词表、语义语法词典、语料库等资源日益丰富

词语切分、词性标注、句法分析等技术快速进步



各种新理论、新方法、新模型层出不穷

互联网和世界经济社会一体化的潮流对NLP技术的迫切需求

当前国内外出现了一批基于NLP技术的应用系统，例如：谷歌、微软、百度等公司纷纷发布个人智能助理；科大讯飞牵头研发高考机器人等。



自然语言处理





# Part 04

## NLP的主要难点

# NLP的主要难点

01

没有规律

02

自由组合

03

开放集合

04

知识依赖

05

上下文



# NLP的主要难点

## 难点1：语言没有规律

自然语言没有什么通用的规律，我们总能找到很多例外的情况。另外，自然语言的组合方式非常灵活，字、词、短语、句子、段落等不同的组合可以表达出很多的含义。例如



都是在表达同一个意思

放首歌黑猫警长  
我要听黑猫警长  
给我播黑猫警长  
我想听歌曲黑猫警长  
给我来一首黑猫警长

# NLP的主要难点

## 难点2：语言可以自由组合

加上百度翻译语音实际演练

语言是可以自由组合的，可以组合复杂的语言表达。比如：


“你知不知道我不知道你知道我是谁”、



“骑车出门差点摔跤，还好我一把把把把住了”、



“我想梦梦梦梦梦过的梦”



试一试？

# NLP的主要难点



## 难点3：开放集合

语言是一个开放集合，我们可以任意地发明创造一些新的表达方式。比如：  
一些网络流行词汇

蓝瘦香菇——难受想哭

emo——忧郁

YYDS——永远的神

特种兵旅游——高强度的旅行方式

i人/e人——内向内倾（Introversion）和  
外向外倾（Extroversion）

内卷/躺平、村超、公主/王子，请...




# NLP的主要难点

## 难点4：语言的使用要基于环境和上下文

语言需要联系实践知识，有一定的知识依赖。比如：

苹果，既可以指一种水果，也可以指苹果公司；



7天，可以表示时间，也可以表示酒店名；



晚安，可以是问候语，也可以是歌名。




## 难点5：上下文

语言的使用要基于环境和上下文。上下文的概念包括很多种：对话的上下文、设备的上下文、应用的上下文、用户画像等。比如：

女孩给男朋友打电话：如果你到了，我还没到，**你就等着吧**；如果我到了，你还没到，**你就等着吧**。



在手机上输入“明天的天气”，设备会显示图文天气信息；而在智能音箱上，设备会直接语音播报天气情况。



# NLP的主要难点

其他：大量歧义（ambiguity）现象



# 谢谢观看

