




自然语言处理

第二章：机器学习与神经网络基础（一）

注意：本PPT仅供个人学习使用，任何组织和个人不得公开传播或用于任何商业盈利用途，否则一切后果由该组织或个人承担。

参考：《自然语言处理》冯建周

授课老师： 缪尧



目录

01

分类算法（决策树）

02

概率模型-隐马尔可夫模型（HMM）

03

聚类算法

Part 01




分类算法

- 1.1 常见分类算法简介
- 1.2 决策树及决策过程
- 1.3 决策树分类算法 (ID3)
- 1.4 决策树模型-案例


1.1 常见分类算法简介

简单来说分类算法就是根据对象的特征或属性，将其划分到已有的类别中，生活中很多场合需要用到分类，比如邮件分类、网页内容分类等。常用的分类算法包括：决策树分类算法、朴素的贝叶斯分类算法（native Bayesian classifier）、支持向量机（SVM）的分类算法等。

✓ 二分类问题




✓ 多分类问题



1.2 决策树模型--决策树及决策过程

决策树算法是一种逼近离散函数值的方法。它是一种典型的分类方法，首先对数据进行处理，利用归纳算法生成可读的规则和决策树，然后使用决策对新数据进行分析。本质上决策树是通过一系列规则对数据进行分类的过程。由于这种决策分支画成图形很像一棵树的枝干，故称为决策树。决策树的生成算法主要有ID3、C4.5和C5.0生成树算法。




1.2 决策树模型--决策树及决策过程

决策树 (decision tree) 是一个树结构，每个非叶节点表示一个特征属性，每个分支代表这个特征属性在某个值域上的输出，每个叶节点存放一个类别。

决策过程：从根节点开始，测试待分类项中相应的特征属性，并按照其值选择输出分支，直到到达叶子节点，将叶子节点存放的类别作为决策结果。

示例：假如我买了一个西瓜，它的特点是**纹理清晰**、**根蒂硬挺**，如何利用下面的决策树判断是好瓜还是坏瓜？




1.2 决策树模型--决策树及决策过程

决策树 (decision tree) 是一个树结构，每个非叶节点表示一个特征属性，每个分支代表这个特征属性在某个值域上的输出，每个叶节点存放一个类别。

决策过程：从根节点开始，测试待分类项中相应的特征属性，并按照其值选择输出分支，直到到达叶子节点，将叶子节点存放的类别作为决策结果。

示例：假如我买了一个西瓜，它的特点是**纹理清晰**、**根蒂稍蜷**、**色泽青绿**，如何利用下面的决策树判断是好瓜还是坏瓜？



1.3 决策树模型--ID3算法


下面以ID3算法为例介绍决策树生成的流程：

(1)从根节点开始，对节点计算所有可能的特征的信息增益，选择信息增益最大的特征作为节点的特征，由该特征的不同取值建立子节点。

(2)对子节点递归地调用以上方法，构建决策树；

(3)直到所有特征的信息增益均很小或没有特征可以选择为止。

最后得到一棵决策树。



1.3 决策树模型--ID3算法

信息熵是接收的每条信息中所包含信息的平均量，是不确定性的量度。熵被定义为概率分布的对数的相反数。依据波尔茨曼H定理（Boltzmann's H-theorem），香农把随机变量X的熵值 $H(X)$ 定义如下，其值域为 $\{x_1, \dots, x_n\}$ 。

$$H(X) = -\sum_i P(x_i) \log(P(x_i))$$

其中 $P(X_i)$ 指的是样本 X_i 的概率。

信息增益（information gain）：用来衡量一个属性区分数据样本的能力。当使用某一个属性作为一颗决策树的根节点时，该属性的信息增益量越大，这颗决策树也就越简洁。信息增益是信息熵H的变形，定义如下：

$$IG(T, a) = H(T) - H(T | a)$$

其中T为样本集，a为样本属性；

$H(T|a)$ 是a为样本属性的时候所对应的熵值，是一种条件熵。

$$H(Y|X) = \sum_x p(x) H(Y|X = x)$$

1.3 决策树模型--ID3算法

《自然语言处理》

A1 A2 A3 A4 决策结果

ID	年龄	工作	自己的房子	信贷情况	类别
1	青年	否	否	一般	否
2	青年	否	否	好	否
3	青年	是	否	好	是
4	青年	是	是	一般	是
5	青年	否	否	一般	否
6	中年	否	否	一般	否
7	中年	否	否	好	否
8	中年	是	是	好	是
9	中年	否	是	非常好	是
10	中年	否	是	非常好	是
11	老年	否	是	非常好	是
12	老年	否	是	好	是
13	老年	是	否	好	是
14	老年	是	否	非常好	是
15	老年	否	否	一般	否

表格是由于15个样本组成的贷款申请训练数据。数据包括贷款申请的4个特征（年龄、是否有工作、是否有自己的房子、信贷情况），最后一列表示是否同意贷款，我们希望利用该训练工具，通过信息增益准则选出最优的分类特征变量。

1.3 决策树模型--ID3算法

A1 A2 A3 A4 决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵-- (依赖于类别):

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

ID					类别
1					否
2					否
3					是
4					是
5					否
6					否
7					否
8					是
9					是
10					是
11					是
12					是
13					是
14					是
15					否

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

ID	年龄	类别
1	青年	否
2	青年	否
3	青年	是
4	青年	是
5	青年	否

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

① 计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

② 计算年龄这一特征变量对数据集分割后的熵:

$$\begin{aligned} H(D|A_1) &= \frac{5}{15} H(D_1) + \frac{5}{15} H(D_2) + \frac{5}{15} H(D_3) \\ &= \frac{5}{15} \left(-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5} \right) + \frac{5}{15} \left(-\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} \right) \\ &\quad + \frac{5}{15} \left(-\frac{4}{5} \log \frac{4}{5} - \frac{1}{5} \log \frac{1}{5} \right) = 0.888 \end{aligned}$$

1.3 决策树模型--ID3算法

A1

A2

A3

A4

决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②计算年龄这一特征变量对数据集分割后的熵:

$$\begin{aligned} H(D|A_1) &= \frac{5}{15} H(D_1) + \frac{5}{15} H(D_2) + \frac{5}{15} H(D_3) \\ &= \frac{5}{15} \left(-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5} \right) + \frac{5}{15} \left(-\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} \right) \\ &\quad + \frac{5}{15} \left(-\frac{4}{5} \log \frac{4}{5} - \frac{1}{5} \log \frac{1}{5} \right) = 0.888 \end{aligned}$$

ID	年龄		类别
6	中年		否
7	中年		否
8	中年		是
9	中年		是
10	中年		是

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1

A2

A3

A4

决策结果

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②计算年龄这一特征变量对数据集分割后的熵:

$$\begin{aligned} H(D|A_1) &= \frac{5}{15} H(D_1) + \frac{5}{15} H(D_2) + \frac{5}{15} H(D_3) \\ &= \frac{5}{15} \left(-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5} \right) + \frac{5}{15} \left(-\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} \right) \\ &\quad + \frac{5}{15} \left(-\frac{4}{5} \log \frac{4}{5} - \frac{1}{5} \log \frac{1}{5} \right) = 0.888 \end{aligned}$$

ID	年龄		类别
11	老年		是
12	老年		是
13	老年		是
14	老年		是
15	老年		否

1.3 决策树模型--ID3算法

A1

A2

A3

A4

决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②计算年龄这一特征变量对数据集分割后的熵:

$$\begin{aligned} H(D|A_1) &= \frac{5}{15} H(D_1) + \frac{5}{15} H(D_2) + \frac{5}{15} H(D_3) \\ &= \frac{5}{15} \left(-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5} \right) + \frac{5}{15} \left(-\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} \right) \\ &\quad + \frac{5}{15} \left(-\frac{4}{5} \log \frac{4}{5} - \frac{1}{5} \log \frac{1}{5} \right) = 0.888 \end{aligned}$$

③年龄特征变量的信息增益:

$$\begin{aligned} IG(D_1, A_1) &= H(D) - H(D|A_1) = 0.971 - 0.888 \\ &= 0.083 \end{aligned}$$

ID	年龄	类别
1	青年	否
2	青年	否
3	青年	是
4	青年	是
5	青年	否
6	中年	否
7	中年	否
8	中年	是
9	中年	是
10	中年	是
11	老年	是
12	老年	是
13	老年	是
14	老年	是
15	老年	否

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

ID	工作	类别
1	否	否
2	否	否
3	是	是
4	是	是
5	否	否
6	否	否
7	否	否
8	是	是
9	否	是
10	否	是
11	否	是
12	否	是
13	是	是
14	是	是
15	否	否

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

ID	A1	工作	A3	A4	类别
1		否			否
2		否			否
5		否			否
6		否			否
7		否			否
9		否			是
10		否			是
11		否			是
12		否			是
15		否			否

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②同理, 计算工作这一特征变量对数据集分割后的熵:

$$H(D|A_2) = \frac{5}{15} H(D_1) + \frac{10}{15} H(D_2)$$

$$= \frac{10}{15} \left(-\frac{4}{10} \log \frac{4}{10} - \frac{6}{10} \log \frac{6}{10} \right) + \frac{5}{15} \left(-\frac{5}{5} \log \frac{5}{5} \right)$$

$$= 0.647$$

1.3 决策树模型--ID3算法

A1 A2 A3 A4 决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②同理, 计算工作这一特征变量对数据集分割后的熵:

$$H(D|A_2) = \frac{5}{15} H(D_1) + \frac{10}{15} H(D_2)$$

$$= \frac{10}{15} \left(-\frac{4}{10} \log \frac{4}{10} - \frac{6}{10} \log \frac{6}{10} \right) + \frac{5}{15} \left(-\frac{5}{5} \log \frac{5}{5} \right)$$

$$= 0.647$$

ID		工作		类别
3		是		是
4		是		是
8		是		是
13		是		是
14		是		是

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

ID	工作	类别
1	否	否
2	否	否
3	是	是
4	是	是
5	否	否
6	否	否
7	否	否
8	是	是
9	否	是
10	否	是
11	否	是
12	否	是
13	是	是
14	是	是
15	否	否

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②同理, 计算工作这一特征变量对数据集分割后的熵:

$$\begin{aligned}
 H(D|A_2) &= \frac{5}{15} H(D_1) + \frac{10}{15} H(D_2) \\
 &= \frac{10}{15} (-\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5}) + \frac{5}{15} (-\frac{5}{5} \log \frac{5}{5}) \\
 &= 0.647
 \end{aligned}$$

③工作特征变量的信息增益:

$$\begin{aligned}
 IG(D_1, A_2) &= H(D) - H(D|A_2) = 0.971 - 0.647 \\
 &= 0.324
 \end{aligned}$$

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

ID	自己的房子	类别
1	否	否
2	否	否
3	否	是
4	是	是
5	否	否
6	否	否
7	否	否
8	是	是
9	是	是
10	是	是
11	是	是
12	是	是
13	否	是
14	否	是
15	否	否

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

1.3 决策树模型--ID3算法

A1 A2 A3 A4 决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②同理, 计算自己的房子这一特征变量对数据集分割后的熵: $H(D|A_3) = \frac{6}{15} H(D_1) + \frac{9}{15} H(D_2)$

$$= \frac{6}{15} (-\frac{6}{6} \log \frac{6}{6}) + \frac{9}{15} (-\frac{5}{5} \log \frac{5}{5} - \frac{6}{10} \log \frac{6}{10})$$

$$= 0.551$$

ID	A1	A2	A3	A4	决策结果
			自己的房子		
4			是		是
8			是		是
9			是		是
10			是		是
11			是		是
12			是		是

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

ID	A1	A2	A3	A4	决策结果
1			自己的房子		否
2			否		否
3			否		是
5			否		否
6			否		否
7			否		否
13			否		是
14			否		是
15			否		否

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②同理, 计算自己的房子这一特征变量对数据集分割后的熵: $H(D|A_3) = \frac{6}{15} H(D_1) + \frac{9}{15} H(D_2)$

$$= \frac{6}{15} (-\frac{6}{6} \log \frac{6}{6}) + \frac{9}{15} (-\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9})$$

$$= 0.551$$

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

ID	自己的房子	类别
1	否	否
2	否	否
3	否	是
4	是	是
5	否	否
6	否	否
7	否	否
8	是	是
9	是	是
10	是	是
11	是	是
12	是	是
13	否	是
14	否	是
15	否	否

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

① 计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

② 同理, 计算自己的房子这一特征变量对数据集分割后的熵: $H(D|A_3) = \frac{6}{15} H(D_1) + \frac{9}{15} H(D_2)$

$$= \frac{6}{15} (-\frac{6}{6} \log \frac{6}{6}) + \frac{9}{15} (-\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9})$$
$$= 0.551$$

③ 自己的房子特征变量的信息增益:

$$IG(D_1, A_3) = H(D) - H(D|A_3) = 0.971 - 0.551$$
$$= 0.420$$

1.3 决策树模型--ID3算法

A1

A2

A3

A4

决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

ID	信贷情况	类别
1	一般	否
2	好	否
3	好	是
4	一般	是
5	一般	否
6	一般	否
7	好	否
8	好	是
9	非常好	是
10	非常好	是
11	非常好	是
12	好	是
13	好	是
14	非常好	是
15	一般	否

1.3 决策树模型--ID3算法

A1 A2 A3 A4 决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

ID		信贷情况	类别
1		一般	否
4		一般	是
5		一般	否
6		一般	否
15		一般	否

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②同理, 计算**信贷情况**这一特征变量对数据集分割后的熵: $H(D|A_4) = \frac{5}{15} H(D_1) + \frac{6}{15} H(D_2) + \frac{4}{15} H(D_3)$

$$= \frac{5}{15} \left(-\frac{1}{5} \log \frac{1}{5} - \frac{4}{5} \log \frac{4}{5} \right) + \frac{6}{15} \left(-\frac{4}{6} \log \frac{4}{6} - \frac{2}{6} \log \frac{2}{6} \right) + \frac{4}{15} \left(-\frac{4}{4} \log \frac{4}{4} \right)$$

$$= 0.608$$

1.3 决策树模型--ID3算法

A1

A2

A3

A4

决策结果

ID		信贷情况	类别
2		好	否
3		好	是
7		好	否
8		好	是
12		好	是
13		好	是

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

① 计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

② 同理, 计算**信贷情况**这一特征变量对数据集分割后的熵: $H(D|A_4) = \frac{5}{15} H(D_1) + \frac{6}{15} H(D_2) + \frac{4}{15} H(D_3)$

$$= \frac{5}{15} (-\frac{1}{5} \log \frac{1}{5} - \frac{4}{5} \log \frac{4}{5}) + \frac{6}{15} (-\frac{4}{6} \log \frac{4}{6} - \frac{2}{6} \log \frac{2}{6}) + \frac{4}{15} (-\frac{4}{4} \log \frac{4}{4})$$

$$= 0.608$$

1.3 决策树模型--ID3算法

A1

A2

A3

A4

决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②同理, 计算**信贷情况**这一特征变量对数据集分割后的熵: $H(D|A_4) = \frac{5}{15} H(D_1) + \frac{6}{15} H(D_2) + \frac{4}{15} H(D_3)$

$$= \frac{5}{15} (-\frac{1}{5} \log \frac{1}{5} - \frac{4}{5} \log \frac{4}{5}) + \frac{6}{15} (-\frac{4}{6} \log \frac{4}{6} - \frac{2}{6} \log \frac{2}{6})$$

$$+ \frac{4}{15} (-\frac{4}{4} \log \frac{4}{4})$$

$$= 0.608$$

ID		信贷情况	类别
9		非常好	是
10		非常好	是
11		非常好	是
14		非常好	是

1.3 决策树模型--ID3算法

A1

A2

A3

A4

决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

A1, A2, A3, A4: 决策树的节点

决策树树根, 选根节点--依赖于信息增益

①计算整个样本数据集的熵:

$$H(D) = - \frac{9}{15} \log \frac{9}{15} - \frac{6}{15} \log \frac{6}{15} = 0.971$$

②同理, 计算**信贷情况**这一特征变量对数据集分割后的熵: $H(D|A_4) = \frac{5}{15} H(D_1) + \frac{6}{15} H(D_2) + \frac{4}{15} H(D_3)$

$$= \frac{5}{15} (-\frac{1}{5} \log \frac{1}{5} - \frac{4}{5} \log \frac{4}{5}) + \frac{6}{15} (-\frac{4}{6} \log \frac{4}{6} - \frac{2}{6} \log \frac{2}{6}) + \frac{4}{15} (-\frac{4}{4} \log \frac{4}{4})$$

$$= 0.608$$

③**信贷情况**特征变量的信息增益:

$$IG(D_1, A_4) = H(D) - H(D|A_4) = 0.971 - 0.608 = 0.363$$

ID		信贷情况	类别
9		非常好	是
10		非常好	是
11		非常好	是
14		非常好	是

1.3 决策树模型--ID3算法

A1

A2

A3

A4

决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

$$IG(D_1, A_1) = 0.083$$


$$IG(D_1, A_2) = 0.324$$

$$IG(D_1, A_3) = \boxed{0.420}$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征 A_3 的信息增益值最大，所以选择 A_3 作为最优特征，此时可构建决策树的第一个节点即根节点(A_3)。

ID	年龄	工作	自己的房子	信贷情况	类别
1	青年	否	否	一般	否
2	青年	否	否	好	否
3	青年	是	否	好	是
4	青年	是	是	一般	是
5	青年	否	否	一般	否
6	中年	否	否	一般	否
7	中年	否	否	好	否
8	中年	是	是	好	是
9	中年	否	是	非常好	是
10	中年	否	是	非常好	是
11	老年	否	是	非常好	是
12	老年	否	是	好	是
13	老年	是	否	好	是
14	老年	是	否	非常好	是
15	老年	否	否	一般	否



1.3 决策树模型--ID3算法

A1 A2 A3 A4 决策结果

ID		自己的房子		类别
4		是		是
8		是		是
9		是		是
10		是		是
11		是		是
12		是		是

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树


$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_2) = 0.324$$

$$IG(D_1, A_3) = 0.420$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征 A_3 的信息增益值最大，所以选择 A_3 作为最优特征，此时可构建决策树的第一个节点即根节点(A_3)。



1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

ID	A1	A2	A3	A4	决策结果
1			自己的房子		否
2			否		否
3			否		是
5			否		否
6			否		否
7			否		否
13			否		是
14			否		是
15			否		否


$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_1) = 0.324$$

$$IG(D_1, A_3) = 0.420$$


$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征 A_3 的信息增益值最大，所以选择 A_3 作为最优特征，此时可构建决策树的第一个节点即根节点(A_3)。




1.3 决策树模型--案例

《自然语言处理》



$$\begin{aligned} IG(D_2, A_1) &= 0.251 \\ IG(D_2, A_2) &= 0.918 \\ IG(D_2, A_4) &= 0.474 \end{aligned}$$

对于 D_2 需要从 A_1 , A_2 和 A_4 中选择新的特征。



1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

ID					类别
	自己的房子				
1	否				否
2	否				否
3	否				是
4	是				是
5	否				否
6	否				否
7	否				否
8	是				是
9	是				是
10	是				是
11	是				是
12	是				是
13	否				是
14	否				是
15	否				否

构建决策树

$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_1) = 0.324$$

$$IG(D_1, A_3) = 0.420$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征 A_3 的信息增益值最大，所以选择 A_3 作为最优特征，此时可构建决策树的第一个节点即根节点(A_3)。

1.3 决策树模型--ID3算法

A1 A2 A3 A4 决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

ID		类别
1		否
2		否
3		是
5		否
6		否
7		否
13		是
14		是
15		否

$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_1) = 0.324$$

$$IG(D_1, A_3) = 0.420$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征 A_3 的信息增益值最大，所以选择 A_3 作为最优特征，此时可构建决策树的第一个节点即根节点(A_3)。

①计算剩余整个样本数据集的熵：

$$H(D) = -\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

ID	年龄	自己的房子	类别
1	青年	否	否
2	青年	否	否
3	青年	否	是
5	青年	否	否
6	中年	否	否
7	中年	否	否
13	老年	否	是
14	老年	否	是
15	老年	否	否

$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_1) = 0.324$$

$$IG(D_1, A_3) = 0.420$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征A₃的信息增益值最大，所以选择A₃作为最优特征，此时可构建决策树的第一个节点即根节点(A₃)。

①计算剩余整个样本数据集的熵：

$$H(D) = -\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

②同理，计算年龄这一特征变量对数据集分割后的熵：

$$H(D|A_1) = \frac{4}{9} H(D_1) + \frac{2}{9} H(D_2) + \frac{3}{9} H(D_3)$$

$$= \frac{4}{9} (-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4}) + \frac{2}{9} (-\frac{2}{2} \log \frac{2}{2})$$

$$+ \frac{3}{9} (-\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3})$$

$$= 0.667$$

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

ID	年龄	类别
1	青年	否
2	青年	否
3	青年	是
5	青年	否
6	中年	否
7	中年	否
13	老年	是
14	老年	是
15	老年	否

$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_1) = 0.324$$

$$IG(D_1, A_3) = 0.420$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征A₃的信息增益值最大，所以选择A₃作为最优特征，此时可构建决策树的第一个节点即根节点(A₃)。

①计算剩余整个样本数据集的熵：

$$H(D) = - \frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

②同理，计算年龄这一特征变量对数据集分割后的熵：

$$H(D|A_1) = \frac{4}{9} H(D_1) + \frac{2}{9} H(D_2) + \frac{3}{9} H(D_3)$$

$$= \frac{4}{9} (-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4}) + \frac{2}{9} (-\frac{2}{2} \log \frac{2}{2})$$

$$+ \frac{3}{9} (-\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3})$$

$$= 0.667$$

1.3 决策树模型--ID3算法

《自然语言处理》

构建决策树

ID	年齢		类别
1	青年		否
2	青年		否
3	青年		是
5	青年		否

$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_1) = \underline{0.324}$$

$$IG(D_1, A_3) = 0.420$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征 A_3 的信息增益值最大，所以选择 A_3 作为最优特征，此时可构建决策树的第一个节点即根节点(A_3)。

①计算剩余整个样本数据集的熵:

$$H(D) = -\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

②同理，计算**年龄**这一特征变量对数据集分割后的熵：

$$H(D|A_1) = \frac{4}{9}H(D_1) + \frac{2}{9}H(D_2) + \frac{3}{9}H(D_3)$$

$$= \frac{4}{9} \left(-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} \right) + \frac{2}{9} \left(-\frac{2}{2} \log \frac{2}{2} \right)$$

$$+\frac{3}{9}(-\frac{2}{3}\log\frac{2}{3}-\frac{1}{3}\log\frac{1}{3})$$

$$= 0.667$$

1.3 决策树模型--ID3算法

A1

A2

A3

A4

决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

ID	年龄	类别
6	中年	否
7	中年	否

$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_1) = 0.324$$

$$IG(D_1, A_3) = 0.420$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征A₃的信息增益值最大，所以选择A₃作为最优特征，此时可构建决策树的第一个节点即根节点(A₃)。

①计算剩余整个样本数据集的熵：

$$H(D) = - \frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

②同理，计算年龄这一特征变量对数据集分割后的熵：

$$H(D|A_1) = \frac{4}{9} H(D_1) + \frac{2}{9} H(D_2) + \frac{3}{9} H(D_3)$$

$$= \frac{4}{9} (-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4}) + \frac{2}{9} (-\frac{2}{2} \log \frac{2}{2})$$

$$+ \frac{3}{9} (-\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3})$$

$$= 0.667$$

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

ID	年龄		类别
13	老年		是
14	老年		是
15	老年		否

$$IG(D_1, A_1) = 0.083$$

$$IG(D_1, A_1) = 0.324$$

$$IG(D_1, A_3) = 0.420$$

$$IG(D_1, A_4) = 0.363$$

综上所述，比较各特征的信息增益值，由于特征A₃的信息增益值最大，所以选择A₃作为最优特征，此时可构建决策树的第一个节点即根节点(A₃)。

①计算剩余整个样本数据集的熵：

$$H(D) = -\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

②同理，计算年龄这一特征变量对数据集分割后的熵：

$$H(D|A_1) = \frac{4}{9} H(D_1) + \frac{2}{9} H(D_2) + \frac{3}{9} H(D_3)$$

$$= \frac{4}{9} (-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4}) + \frac{2}{9} (-\frac{2}{2} \log \frac{2}{2})$$

$$+ \frac{3}{9} (-\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3})$$

$$= 0.667$$

1.3 决策树模型--ID3算法

$$H(X) = -\sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1

A2

A3

A4

决策结果

构建决策树

ID	年龄		类别
1	青年		否
2	青年		否
3	青年		是
5	青年		否
6	中年		否
7	中年		否
13	老年		是
14	老年		是
15	老年		否

①计算剩余整个样本数据集的熵:

$$H(D) = -\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

②同理, 计算年龄这一特征变量对数据集分割后的熵:

$$H(D|A_1) = \frac{4}{9} H(D_1) + \frac{2}{9} H(D_2) + \frac{3}{9} H(D_3)$$

$$= \frac{4}{9} \left(-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} \right) + \frac{2}{9} \left(-\frac{2}{2} \log \frac{2}{2} \right) + \frac{3}{9} \left(-\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3} \right)$$

$$= 0.667$$

③年龄特征变量的信息增益:

$$IG(D_2, A_1) = H(D_2) - H(D_2|A_1) = 0.918 - 0.667 = 0.251$$

1.3 决策树模型--ID3算法

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

A1 A2 A3 A4 决策结果

构建决策树

ID	A1	工作	A3	A4	类别
1		否			否
2		否			否
3		是			是
5		否			否
6		否			否
7		否			否
13		是			是
14		是			是
15		否			否

①计算剩余整个样本数据集的熵:

$$H(D) = -\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

②同理, 计算工作这一特征变量对数据集分割后的熵:

$$H(D|A_2) = \frac{6}{9} H(D_1) + \frac{3}{9} H(D_2)$$

$$= \frac{6}{9} (-\frac{6}{6} \log \frac{6}{6}) + \frac{3}{9} (-\frac{3}{3} \log \frac{3}{3})$$

$$= 0$$

③工作特征变量的信息增益:

$$IG(D_2, A_2) = H(D_2) - H(D_2|A_2) = 0.918 - 0 = 0.918$$

1.3 决策树模型--ID3算法

A1 A2 A3 A4 决策结果

$$H(X) = - \sum_i P(x_i) \log(P(x_i))$$

《自然语言处理》

构建决策树

ID		自己的房子	信贷情况	类别
1		否	一般	否
2		否	好	否
3		否	好	是
5		否	一般	否
6		否	一般	否
7		否	好	否
13		否	好	是
14		否	非常好	是
15		否	一般	否

①计算剩余整个样本数据集的熵:

$$H(D) = -\frac{3}{9} \log \frac{3}{9} - \frac{6}{9} \log \frac{6}{9} = 0.918$$

②同理, 计算**信贷情况**这一特征变量对数据集分割后的熵: $H(D|A_4) = \frac{4}{9}H(D_1) + \frac{4}{9}H(D_2) + \frac{1}{9}H(D_3)$

$$= \frac{4}{9}(-\frac{4}{4} \log \frac{4}{4}) + \frac{4}{9}(-\frac{2}{4} \log \frac{2}{4} - \frac{2}{4} \log \frac{2}{4}) + \frac{1}{9}(-\frac{1}{1} \log \frac{1}{1})$$

$$= ?$$

③**信贷情况**特征变量的信息增益:

$$IG(D_2, A_2) = H(D_2) - H(D_2|A_4) = 0.918 - ?$$

$$= 0.363$$

1.3 决策树模型--案例


同理可得：

$$IG(D_1, A_2) = H(D) - \left(\frac{5}{15} H(D_1) + \frac{10}{15} H(D_2) \right) = 0.324$$

$$IG(D_1, A_3) = 0.971 - 0.551 = 0.420$$

$$IG(D_1, A_4) = 0.971 - 0.608 = 0.363$$

综上所述，比较各特征的信息增益值，由于特征 A_3 的信息增益值最大，所以选择 A_3 作为最优特征。此时可构建决策树的第一个节点即根节点（ A_3 ）。



Part 02



概率图模型--HMM

2.1 隐马尔可夫模型 (HMM)


2.2 HMM的应用领域

2.3 HMM示例

2.1 隐马尔可夫模型(HMM)

- 隐马尔可夫模型(Hidden Markov Mode, HMM)是关于时序的概率模型;
- 描述由一个隐藏的马尔可夫链随机生成不可观测的状态随机序列(state sequence),再由各个状态生成一个观测而产生观测随机序列(observation sequence)的过程,序列的每一个位置又可以看作是一个时刻。

$$P(x_1, y_1, \dots, x_n, y_n) = P(y_1)P(x_1 | y_1) \prod_{i=2}^n P(y_i | y_{i-1})P(x_i | y_i)$$




2.2 隐马尔可夫模型(HMM)--应用领域


《自然语言处理》

- 人脸识别
- 语音识别
- NLP领域

https://www.bilibili.com/video/BV1UN4y1h71g/?spm_id_from=333.337.search-card.all.click&vd_source=852986d37ebf7f3667eb666215641be3



- 1) 提取人脸的特有向量;
- 2) 建立公用的隐马尔科夫模型, 确定初始参数;
- 3) 训练初始模型, 训练均匀分割得到的参数, 以求得最佳的分割点;
- 4) 重新计算模型的初始参数;
- 5) 重复以上过程, 直到模型收敛为止。



2.2 隐马尔可夫模型(HMM)--应用领域


《自然语言处理》

- 人脸识别
- 语音识别
- NLP领域



- 1) 信号处理阶段：特征抽取阶段，将声学模型切分为音片框架，再转换成音谱特征；
- 2) 因子阶段：押词阶段，利用高斯模型或者是神经网络等统计技术，来识别单个的因子；
- 3) 解码阶段：利用单词、发音词或语言模型，采用维特比算法，来获取最大概率的单词序列。

https://www.bilibili.com/video/BV1Hb41187e1/?spm_id_from=333.788.recommend_more_video.0&vd_source=852986d37ebf7f3667eb666215641be3



2.2 隐马尔可夫模型(HMM)--应用领域


《自然语言处理》

- 人脸识别
- 语音识别
- NLP领域




词性标注：
隐藏状态下的值

可观测值




2.3 隐马尔可夫模型(HMM)--示例


假设有3种不同的骰子，第一个骰子是我们平常见的骰子（称这个骰子为D6），6个面，每个面（1，2，3，4，5，6）出现的概率是1/6。第二个骰子是个四面体（称这个骰子为D4），每个面（1，2，3，4）出现的概率是1/4。第三个骰子有八个面（称这个骰子为D8），每个面（1，2，3，4，5，6，7，8）出现的概率是1/8。



D6(1,2,3,4,5,6)




D4(1,2,3,4)




D8(1,2,3,4,5,6,7,8)

2.3 隐马尔可夫模型(HMM)--示例




2.3 隐马尔可夫模型(HMM)--示例

举例来说，有三个骰子，六面骰，四面骰，八面骰。也知道掷了三次的结果（1 6 3），但不知道每次用了那种骰子，**求最有可能的骰子序列**。（假设每次扔骰子都是独立事件）



下面使用Viterbi算法对该问题进行求解。




$$P_1(D4) = P(D4) * P(D4 \rightarrow 1) = 1/3 * 1/4$$

$$P_1(D6) = P(D6) * P(D6 \rightarrow 1) = 1/3 * 1/6$$


$$P_1(D8) = P(D8) * P(D8 \rightarrow 1) = 1/3 * 1/8$$

2.3 隐马尔可夫模型(HMM)--示例

举例来说，有三个骰子，六面骰，四面骰，八面骰。也知道掷了三次的结果（1 6 3），但不知道每次用了那种骰子，**求最有可能的骰子序列**。



下面使用Viterbi算法对该问题进行求解。



$$P1(D4)=P(D4)*P(D4 \rightarrow 1)=1/3*1/4$$

$$P1(D6)=P(D6)*P(D6 \rightarrow 1)=1/3*1/6$$


$$P1(D8)=P(D8)*P(D8 \rightarrow 1)=1/3*1/8$$

$$P2(D6)=P1(D4)*P(D6)*P(D6 \rightarrow 6)=1/3*1/4*1/3*1/6$$


$$P2(D8)=P1(D4)*P(D8)*P(D8 \rightarrow 6)=1/3*1/4*1/3*1/8$$

2.3 隐马尔可夫模型(HMM)--示例

举例来说，有三个骰子，六面骰，四面骰，八面骰。也知道掷了三次的结果（1 6 3），但不知道每次用了那种骰子，**求最有可能的骰子序列**。



下面使用Viterbi算法对该问题进行求解。



$$P1(D4)=P(D4)*P(D4 \rightarrow 1)=1/3*1/4$$

$$P1(D6)=P(D6)*P(D6 \rightarrow 1)=1/3*1/6$$

$$P1(D8)=P(D8)*P(D8 \rightarrow 1)=1/3*1/8$$

$$P3(D4)=P2(D6)*P(D4)*P(D4 \rightarrow 1)=1/3*1/4*1/3*1/6*1/3*1/4$$

$$P3(D6)=P2(D6)*P(D6)*P(D6 \rightarrow 1)=1/3*1/4*1/3*1/6*1/3*1/6$$

$$P3(D8)=P2(D6)*P(D8)*P(D8 \rightarrow 1)=1/3*1/4*1/3*1/6*1/3*1/8$$


$$P2(D6)=P1(D4)*P(D6)*P(D6 \rightarrow 6)=1/3*1/4*1/3*1/6$$

$$P2(D8)=P1(D4)*P(D8)*P(D8 \rightarrow 6)=1/3*1/4*1/3*1/8$$


2.3 隐马尔可夫模型(HMM)--示例

《自然语言处理》

举例来说，有三个骰子，六面骰，四面骰，八面骰。也知道掷了三次的结果（1 6 3），但不知道每次用了那种骰子，**求最有可能的骰子序列**。



下面使用Viterbi算法对该问题进行求解。



https://www.bilibili.com/video/BV1Gz4y1p7Np/?spm_id_from=333.337.search-card.all.click&vd_source=852986d37ebf7f3667eb666215641be3

Part 03




聚类算法

3.1 聚类算法概述

3.2 原型聚类

- 概率图模型(probabilistic graphical model)是一类用图来表达变量相关关系的概率模型
- 概率图模型提供了一种描述框架
 - 结点：随机变量（集合）
 - 边：变量之间的依赖关系
- 分类：
 - 有向图：
 - 使用有向无环图表示变量之间的依赖关系
 - 无向图：
 - 使用无向图表示变量间的相关关系



常见的概率图模型包括：隐马尔可夫模型（HMM），条件随机场模型（CRF）和LDA模型。

条件随机场模型主要思想来源于HMM，也是一种用来标记和切分序列化数据的统计模型。不同的是，条件随机场是在给定观察的标记序列下，计算整个标记序列的联合概率，而HMM是在当前给定的状态下，定义下一个状态分布。

条件随机域场（conditional random fields，简称 CRF，或CRFs），是一种判别式概率模型，是随机场的一种，常用于标注或分析序列资料，如自然语言文字或是生物序列。条件随机场是条件概率分布模型 $P(Y|X)$ ，表示的是给定一组输入随机变量 X 的条件下另一组输出随机变量 Y 的马尔可夫随机场，也就是说CRF的特点是假设输出随机变量构成马尔可夫随机场。条件随机场可被看作是最大熵马尔可夫模型在标注问题上的推广。

LDA算法假设文档中主题的先验分布和主题中词的先验分布都服从**狄利克雷分布**。在贝叶斯学派看来，先验分布+数据（似然）=后验分布。我们通过对已有数据的统计，就可以得到每篇文档中主题的多项式分布和每个主题对应词的多项式分布，也就是我们最后需要的结果。那么具体的LDA模型应当如何进行求解，其中一种主流方法就是吉布斯采样。结合吉布斯采样的LDA模型训练过程一般如下：

- （1）随机初始化，对语料中每篇文档中的每个词 w ，随机地赋予一个topic编号 z 。
 - （2）重新扫描语料库，对每个词 w 按照吉布斯采样公式重新采样它的topic，在语料中进行更新。
 - （3）重复以上语料库的重新采样过程直到吉布斯采样收敛。
 - （4）统计语料库的topic-word共现频率矩阵，该矩阵就是LDA模型。
- 经过以上的步骤，就得到一个训练好的LDA模型。

3.1 聚类算法概述


聚类算法是无监督学习的典型算法，不需要标记结果。试图探索和发现一定的模式，用于发现共同的群体，按照内在相似性将数据划分为多个类别使得**内内相似性大**，**内间相似性小**。应用场景包括新闻聚类、用户购买模式、图像与基因技术等。

常见的聚类算法包括：

- (1) **原型聚类**：原型聚类亦称为“基于原型的聚类”，此类算法假设聚类结构能通过一组原型刻画，在现实聚类任务中极为常用。
- (2) **密度聚类**：密度聚类亦称为“基于密度的聚类”，此类算法假设聚类结构能通过样本分布的紧密程度确定。
- (3) **层次聚类**：层次聚类算法试图在不同层次对数据集进行划分，从而形成树形的聚类结构。数据集的划分可采用“自底向上”的聚合策略，也可采用“自顶向下”的分拆策略。

原型聚类亦称为“**基于原型的聚类**”，此类算法假设聚类结构能通过一组原型刻画，在现实聚类任务中极为常用。通常情形下，算法先对原型进行初始化，然后对原型进行迭代更新求解。采用不同的原型表示、不同的求解方式，将产生不同的算法。下面介绍经典的原型聚类算法k-means也称为k均值法。下面介绍经典的原型聚类算法k-means也称为k均值法。

算法思想就是首先随机确定k个中心点作为聚类中心，然后把各个数据点分配给最邻近的中心点，分配完成后将中心点移动到所表示的聚类的平均中心位置处，然后重复迭代上述步骤，直到分配过程不再产生变化位置。



3.2 原型聚类--k-means算法

k-means算法采用距离作为相似性指标，认为簇由靠近的对象组成，因此两个对象的距离越近，则其相似度越大。而不同的距离量度会对聚类的结果产生影响，常见的距离量度如下所示：

(1) 欧氏距离: $d_{12} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$

(2) 曼哈顿距离: $d_{12} = |x_1 - x_2| + |y_1 - y_2|$

(3) 切比雪夫距离: $d_{12} = \max(|x_1 - x_2|, |y_1 - y_2|)$

(4) 余弦距离: $\cos \theta = \frac{x_1 x_2 + y_1 y_2}{\sqrt{x_1^2 + y_1^2} \sqrt{x_2^2 + y_2^2}}$

(5) Jaccard 相关系数: $J(A, B) = \frac{|A \cap B|}{|A \cup B|}$

(6) 相关系数: $\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)} \sqrt{D(Y)}} = \frac{E((X - EX)(Y - EY))}{\sqrt{D(X)} \sqrt{D(Y)}}$

3.2 原型聚类--k-means算法

《自然语言处理》

k-means算法流程：

- (1) 随机选择K个随机的点（称为聚类中心）；
- (2) 对与数据集中的每个数据点，按照距离K个中心点的距离，将其与距离最近的中心点关联起来，与同一中心点关联的所有点聚成一类；
- (3) 计算每一组的均值，将该组所关联的中心点移动到平均值的位置；
- (4) 重复执行2-3步，直至中心点不再变化；

